

機械学習

R による初めてのデータ分析

川田恵介

東京大学

keisukekawata@iss.u-tokyo.ac.jp

2025-08-13

1 概念整理

1.1 データ分析法

- = 事例から学ぶ方法
- 過去の経験や事例、歴史（データ）を活用し、意思決定に役立つ情報提供
 - ▶ 各顧客は、どのようなサービスを好みのか？
 - ▶ 事業全体で価格を上げると、どの程度需要が下がるのか？
 - ▶ どのような事業領域が伸びているのか？

1.2 実務への影響

- すでに多くの活用事例がある
 - ▶ MicroSoft, CyberAgent, 日経センター
 - ▶ 金融機関 (Bank of England)
- 事例紹介 + 考察
 - ▶ 予測マシンの世紀 AI が駆動する新たな経済

1.3 データ分析の諸分野

- 統計学、計量経済学、医療統計、**機械学習**
 - ▶ 異なるコミュニティ(例: 機械学習 = “AI の研究”)によって発展
 - ▶ 融合が急速に進む
 - ▶ 分析方法ごとの特徴を理解し、適した手法を採用することが重要に

1.4 到達目標

- 自身でデータ分析を行うための入門

- ・ 事例分析の抱える不透明性(Uncertainly)への対処に焦点
- ・ データ分析の結果を意思決定に活用するための必要知識の取得
- ・ エントリーシートなどに、“AIを用いた予測モデル/レポート作成経験”と書けるようにする

2 不透明性 (Uncertainly)

- ・ データ分析を含む事例分析の一般的課題
 - ・ 独立した分析チームに**同じ市場/社会**の分析を依頼したとしても、同じ結論に到達し得ない
 - 誰がやっても、「水は 100 度で沸騰する」という結論に到達する理科の実験とは対照的

2.1 “個別事例分析”

- ・ 東京 23 区の中古マンションにおける”取引価格の特徴”について、2539 事例 (2021 年第 1 四半期) から含意を得る
- ・ 最低価格で取引されている物件は
- ・ “足立区の 3 5 平米の物件の取引価格は 500 万円” と主張できるか？

2.2 “個別事例分析”

- ・ 全く同じ属性を持つ物件は、他にも存在する
- ・ データから観察できない要因で、この事例の取引価格が下振れているのでは？

2.3 要約計画

- ・ 大規模なデータになると、両親の学歴が同じ大量の事例
 - ・ 何らかの要約を用いて、集団の”傾向”を論じる
 - 典型的な事例の報告、研究者の所見/印象、平均値、中央値、分散
- ・ 恣意的分析を避けるために、データを見る前に、要約計画を立てることが重要
 - ・ 平均などの”自動計算”できる方法が有効

2.4 実例

2.5 実例

2.6 Sampling Uncertainly の軽減

- ・ 中野区 25 平米は 2 事例のみ = 平均取引価格は 17.9
- ・ データを取りなおしたら、違う結果になるのでは？

- ▶ データから観察できない価格決定要因の”偏り”が、データ固有の特徴を生み出す
- ▶ 観察する事例が人によって異なるため、結論が異なる (Sampling uncertainly)
- 対策: 多くの事例を集計(モデル化)し、傾向把握を行う

2.7 サブサンプル分析

1. 分析者が、サブグループ (モデル) を定義する
 - 例: 足立区かどうか × 部屋の広さが 55 平米以下かどうか
2. サブグループの平均値を計算
 - 集計により Sampling uncertainly を軽減する

2.8 サブサンプル分析

2.9 サブサンプル分析の利点

- データが、関心となる集団(日本全体など) からランダムサンプリングにより生成されていれば、以下の優れた理論的性質をもつ
 - ▶ 無限大の事例数で、Sampling Uncertainly は消失する
 - ▶ そこそこの事例数で、信頼区間を近似計算できる
 - 一定の確率で母平均を含む区間
 - 偶然生じた傾向か否かを区別でき、重大な意思決定への活用において、特に望ましい性質

2.10 例: 信頼区間

2.11 Model Uncertainly

- モデルの定義を変えると、推定結果が大きく変化する
- 事例の要約方法(モデル化)が属人的で、不透明 (Model uncertainly)
 - ▶ 多くの教科書で直接的な言及を避けてきた問題
 - 「理論や背景をしっかりと踏まえて、適切なモデル化を行うべし」以上の提案が難しい
 - ▶ 機械学習の適切な活用で、軽減できる

2.12 付論: Model Uncertainly の副作用

- モデルを色々試すことで、分析者にとって”望ましい結果” (例: 明確な因果効果、存在しない格差の存在”証明”など)を、“捏造”できる
 - ▶ Cherry-pick/p-huck などと呼ばれる
- 無実の証明が難しい

- ▶ 疑われないようにするために、“複雑な分析”を避ける傾向
 - 例: どのような背景属性の組み合わせると、改装は大きな効果を持つか?

2.13 Model Uncertainty の軽減

- モデルの根拠の明示することが重要
1. 分析課題が詳細に決まっているケース
 - 例: “足立区と物件と他を比較することが重要”
 - ▶ 詳細まで決まっていないケースはまれ
 2. 何らかの一般基準に基づくモデル生成
 - 機械学習活用に比較優位

2.14 機械学習の活用

- 決定木アルゴリズム: データに最も適合するように、サブグループを定義する
 - ▶ 明確な基準(“データへの適合”)のもとで、要約方法を決定
 - 選定基準の明確化による Model Uncertainty の”削減”
 - 予測研究であれば、説得的な基準

2.15 例

- 最大 4 グループに分けることは前提に、平均二乗誤差

$$(Y - \text{モデルの予測値})^2$$
 のデータ上での平均値

を可能な限り削減するようにグループ分けを行う

 - ▶ 近似的に削減する (Greedy-algorithm)

2.16 実例

2.17 例. 複雑なモデル

- 機械学習を用いれば、より複雑なモデルも容易に生成できる
- 例. 最大 32 グループに分ける

2.18 複雑なモデル

3 意思決定問題への応用

3.1 意思決定問題

- 意思決定 = 状況把握/予測 + 判断
 - ▶ 今日、傘を持って出かけるか?

- 状況把握: 雨が降るか/人に会うか/体調はどうか
- 判断: 雨に濡れることは、どのくらい問題か?
- ▶ どの事業に経営資源を収集するのか?
- 状況把握: 各事業の現状、将来性
- 判断: 企業の経営目標に寄り添うのは?

3.2 “ミクロな”意思決定

- 個別”事例”のみに影響を与える意思決定
 - ▶ 医療データ: 患者ごとの治療方針
 - ▶ 不動産データ: 中古マンションの買取
 - ▶ 労働市場: 労働者ごとの 30 年後の賃金
- “事例ごとの”状況把握が必要
 - ▶ 複雑なモデルを用いた、個別予測が有効
 - 機械学習の活用に大きな利点

3.3 実例

- 転職の意思決定
 - ▶ 状況把握: 自身の市場価値
 - 例: レバテックのサイト
 - ▶ 判断: どのような働き方をしたいか

3.4 実習例: 取引価格予測モデル

3.5 “マクロな”意思決定への応用

- 影響の範囲が広い(“マクロな”)意思決定に対しては、個別事例の予測値”そのもの”の便益は限定的
 - ▶ 例. 政策決定、企業の戦略決定
- 影響を与える(大量の)事例の特徴について、意思決定者が理解できる情報提供が必要
 - ▶ 大量の予測値を示されても、理解できない
 - ▶ 幅広い合意形成に向けた、幅広い情報伝達が難しい
- 事例のシンプルな要約であれば、伝統的な統計手法に大きな比較優位

3.6 実例

- 中期経営計画: 就業者や株主、世間に伝えやすい、集計情報に基づいて、現状分析/経営方針を説明
 - ▶ セブン & アイ
- 白書: 有権者等に向けて、集計情報に基づいた、現状分析/政策方針を説明
 - ▶ 労働経済白書

3.7 実習例: 平均取引価格の推移

3.8 What-if 分析

- 伝統的な手法 + 機械学習によって、より柔軟な集計が可能
- 本講義では、Balanced comparison を議論する。
 - ▶ 因果推論、格差、現状分析において、非常に重要な分析方法となっている。
 - ▶ 伝統的な統計学/機械学習の教科書では、紹介されていない

3.9 実例. 既存店ベースの比較

- あるコンビニチェーンで、店舗あたりの平均売り上げが 1000 万円増大した
- 去年から今年にかけて、新規出店が大きく増加した
 - ▶ 売り上げが大きくなる傾向のある新規店の割合が大きく、結果、平均売り上げが増大したのではないか?
- 既存店に絞って、比較する

3.10 実例. 客層

- あるコンビニチェーンで、大手町店と本郷三丁目店で、客単価が大きく異なる
 - ▶ 客層の違いに起因しているのではないか?
 - 本郷三丁目の方が、大学生が多い等
- 来客の年齢の分布を仮想的に揃えて、比較する

3.11 実例. 因果推論

- コンビニの改装が平均的にどの程度、平均売上を上昇させるのか
 - ▶ 「改装するかどうかの意思決定、および価格に影響を与える変数」(Confounders)が偏る
 - ▶ データから観察できる Confounders については、分布を揃える必要がある

3.12 実習例: 2021-2023 年比較

- 取引価格のみならず、取引物件の性質も変化している

3.13 実習例: 取引価格の変化

3.14 まとめ

- 意思決定に応じて、必要な情報の”細かさ”が異なる
- “細かさ”が異なれば、最適な手法が異なる可能性がある
 - ▶ 事例ごとの予測を提供するのであれば、現状、機械学習には大きな優位性がある
 - ▶ シンプルな集計情報であれば、伝統的な推定方法 (平均値など)の実用性が高い
 - ▶ 複雑な集計情報であれば、伝統的な推定方法と機械学習との併用が有効

4 R

- Python と並ぶ、データ分析の人気言語
 - ▶ 高い透明性と拡張性、再現可能性、無料
 - ▶ 多様な統合開発環境(IDE)

4.1 準備

- Posit cloud への登録
 - ▶ クラウド環境で R を使用できる
 - ▶ ただし時間制限あり
- 関心がある人は、自身の PC へ Rstudio をインストール
 - ▶ 時間無制限

4.2 Example code

- コードを実行する際には、(慣れるまでは)、以下の手順を徹底
1. ctr + a を押し、全ての行を選択する
 2. ctr + enter を押し、実行する

4.3 Error が出たら

- 「error は必ず起きる」、という心構えをもつ
- 再現性の確認： 全ての行を再度実行
 - ▶ コード実行しわすれ、がエラーの原因となることが多い
- よくあるミス (大文字/小文字の区別、コンマ)を確認
 - ▶ 極力予測変換を活用し、タイポを減らす
- 解決できない場合は、コード全体をチャット欄にコピペしてください