

効果の異質性

事例の集計

川田恵介

テキストデータ: Get Started

例

- 日本 & 経済学におけるコロナ研究リスト

A tibble: 266 x 2

Title	Type
<chr>	<chr>
1 新型コロナ対策としてのマスク着用義務化——アメリカの政策評価と日本への示~	一般
2 現状放置なら5月下旬に緊急事態宣言の恐れ	一般
3 接触確認アプリ COCOA を行動経済学で読み解く	一般
4 新型コロナ対策がもたらす効果の定量的分析〜緊急事態宣言解除後のシナリオ~	一般
5 新型コロナ危機と経済政策	一般
6 感染症データにおける「従属性」と因果推論	一般
7 「疫学」と「マクロ経済学」の視点から —最新論文に見る感染症対策と経済活~	一般
8 コロナ危機は需要ショックなのか供給ショックなのか？	一般
9 コロナ危機の経済学：提言と分析	一般
10 新型コロナウイルスのマクロ経済学（1）感染症拡大防止政策のトレードオフ	一般

i 256 more rows

テキスト分析

- 事例の多くは、“テキスト”で記録されてきた
 - 膨大な電子化されたテキストデータがより容易に入手可能（SNS, オンラインアンケート、口コミ評価）
- テキスト分析への需要拡大
 - 統計・機械学習的手法の応用が急速に進む

例：自由記述欄

- 多くの調査には、自由記述欄が含まれる
 - 例：商品への感想を書いてください
- Open end question（回答結果を制約しない）
 - いろんな回答結果が記録できる
 - 分析者が想定していない情報を得られる可能性

例：武蔵大学の印象

```
# A tibble: 3 x 2
  ID Text
<dbl> <chr>
1      1 キャンパスが綺麗
2      2 池袋から近い
3      3 キャンパスがおしゃれ
```

予測研究への応用

- テキストから他の変数を予測できるか？
 - $E_P[Y|\text{テキスト}]$ を推定できるか？
- 機械学習に比較優位

復習：母平均の推定問題

- 基本：“似ている” 複数の事例を集計して、 $E_P[Y|X]$ を推定したい
- 予測変数 X の役割 = 似ている事例かどうかの判断基準
 - 統計・機械学習 = データから似ている度を判定する
- 伝統的な X ：カテゴリー/連続変数
 - テキストは大きく異なる特徴を持つ

VS カテゴリー変数

- 性別、国籍、学部など
- カテゴリー変数 = “少数” の値しかとらない
 - 同じ値をとるサンプルが複数存在
 - “値が同じであれば似ている”
- テキスト変数 = 無限大の種類がある

VS 連続変数

- 年齢、身長など
- 連続変数 = 同じ値をとるサンプルは極めて少数
 - 値が近いかどうかは自明
- テキスト変数
 - テキストが近いかどうかは自明ではない

テキスト変数の難しさ

- テキストは情報が”豊富”すぎる
- 変数の値間の距離が定義できない
 - 似ている文章とは？
- → 何らかの単純化が必要

テキストデータを使った予測モデル構築

- 予測モデル $g(X, Text)$ を構築
- 合わせ技でモデル構築
 - 事前に $Text$ を単純化する (前処理)
 - 大量の X に対応した手法で推計

前処理: Token

- テキストを単語の羅列 (Token 化)
- 日本語は単語化が難しい
 - 分かち書きをしない
 - quanteda パッケージを用いれば解決可能

例: 武蔵大学の印象

Tokens consisting of 3 documents and 1 docvar.

text1 :

[1] "キャンパス" "が" "綺麗"

text2 :

[1] "池袋" "から" "近い"

text3 :

[1] "キャンパス" "が" "おしゃれ"

前処理: Bag of words

- Token 化しただけでは、依然として、全ての事例が異なる値を有する
 - さらなる単純化が必須
- 代表的な手法は、Bag of words
 - 単語の出現頻度を数える
- 文脈や語順は捨象
 - 発展: N-gram, embedding