

概要

川田恵介

2026-09-08

1 環境設定

1.1 講義資料

- tetokawata と検索し, UnderGradEconML をクリック (講義のレポジトリ)
- Public をクリックし, 01Introduction.pdf をダウンロード
- 当該ページをブックマーク登録
 - github のアカウントを持っている場合は, お気に入り登録

1.2 成績評価

- 第2回目から講義終了後にミニテスト + レポート
 - 最も成績の良い8回を評価の対象とする

2 データ分析法

2.1 データ分析法

- 過去の経験や事例、歴史(データ)から、意思決定や社会の把握に有効な情報を抽出する
- 意思決定に役立つ情報提供を目指す
 - 各顧客は、どのようなサービスを好みのか?
 - 事業全体で価格を上げると、どの程度需要が下がるのか?
 - どのような事業領域が伸びているのか?
- “AI”にも活用されている
 - ある質問文について、代表的な回答は?

2.2 現状

- 実務/学術/政府機関から高い関心¹

¹Amazon, Cyber Agent, Microsoft, Mizuho, Netflix, Uber

- 参考文献: 事例紹介 + 考察
 - ▶ 予測マシンの世紀 AI が駆動する新たな経済

2.3 近年の発展

- 機械学習: 予測モデルの推定がメイン
 - ▶ AI (Gemini, ChatGPT 等) の基盤
- 機械学習 + 計量経済学を身につけることで、因果効果や格差研究等への応用も可能に
 - ▶ 大学院レベルの教科書²が書かれる段階になっている

2.4 到達目標

- 自身でデータ分析を行う/活用するための入門
 - ▶ データ分析の不完全性への対処に焦点
- “専門家”や”AI”が出力する「流暢な自信満々の嘘」を見抜く力をつける
- エントリーシートなどに、“AI/機械学習を用いた不動産市場についての、予測・因果モデルを作成経験した経験あり”と書けるようにする

3 Get started

3.1 一般的課題

- (データ分析を含む)事例分析の共通課題
 - ▶ 独立した分析チームに同じ市場/社会について、事例収集とデータ分析を依頼したとしても、同じ結論に到達し得ない
 - 誰がやっても、「水は 100 度で沸騰する」という結論に到達する理科の実験とは対照的

3.2 データ

- 現代の分析では、大量の事例が含まれるデータを利用する機会が多い
 - ▶ 実習で用いるデータには、11311 事例と 13 変数が含まれ、合計 147043 個の数字がある
 - 人間には認識不可能

3.3 “個別事例分析”

- 特徴的な事例を研究者が選別する
- 最高価格で取引されている物件は

²Applied Causal Inference Powered by ML and AI

Price	District	Size
1,400	杉並	105

- “杉並区の 105 平米の物件の取引価格は 1 億 4000 万円” と主張できるか？

3.4 “個別事例分析”の問題点

- 全く同じ属性を持つ物件は、他にも存在する


Price	District	Size
85	杉並	105
160	杉並	105
93	杉並	105
110	杉並	105
1,400	杉並	105

- データから観察できない要因で、先の事例は大幅に上振れたのでは？

3.5 伝統的アプローチ

1. 分析者が、サブグループ (モデル) を定義する
 - 例: 練馬区かどうか × 部屋の広さが 55 平米以下かどうか
2. サブグループの平均値を計算
 - 集計により偶然の上振れ/下振れの影響を軽減する

3.6 伝統的アプローチ



3.7 伝統的方法の問題点

- モデルの設定が属人的で、不透明
 - ▶ 推定結果を大きく左右してしまう
 - 多くの教科書が、直接的な言及を避けてきた問題
 - ▶ 機械学習の適切な活用が有効


3.8 機械学習的アプローチ

- 回帰木: データに最も適合するように、サブグループを定義する
 - ▶ サブグループ分け自体をデータ主導で行う

3.9 例

- 最大4グループに分けることは前提に、データに可能な限り適合するようにグループ分けを行う

3.10 実例



4 Takeaway

4.1 伝統的アプローチの利点と課題

- **利点:** 研究者が設定したシンプルなモデルについて、データの偏りの影響を評価しながら、推定/推論できる
- **課題:** 予測性能は、研究者が設定したモデルに強く依存する

4.2 機械学習の利点と課題

- **利点:** データ主導で、モデルを推定できる
- **課題:** データの偏りに起因する、不確実性の評価が難しい
 - ▶ 人間行動など個人差が大きい変数を予測することは難しい
 - 社会/市場分析への活用が難しい

4.3 本講義の提案

- 機械学習と伝統的な統計学/計量経済学/医療統計等の手法と”併用”する

4.4 予習資料

- 入門的な統計学 + R
 - ▶ Statistical Inference via Data Science

- 機械学習
 - ▶ Introduction to Statistical Learning (Trevor Hastie, Robert Tibshirani, Jerome Friedman)

5 R

5.1 R

- Python と並ぶ、データ分析の人気言語
 - ▶ 高い透明性と拡張性、再現可能性、無料、AI 活用にも便利
 - ▶ 多様な統合開発環境(IDE)の選択肢がある

5.2 準備

- Posit cloud への登録
 - ▶ クラウド環境で R を使用できる
 - ▶ ただし時間制限あり
- 関心がある人は、自身の PC へ Positron/Rstudio をインストール
 - ▶ 時間無制限

5.3 Example code

- コードを実行する際には、(慣れるまでは)、以下の手順を徹底
 1. ctr + a を押し、全ての行を選択する
 2. ctr + enter を押し、実行する

5.4 Error が出たら

- 「error は必ず起きる」、という心構えをもつ
- 再現性の確認： 全ての行を再度実行
 - ▶ コード実行しわすれ、がエラーの原因となることが多い
- よくあるミス (大文字/小文字の区別、コンマ)を確認
 - ▶ 極力予測変換を活用し、タイポを減らす
- 解決できない場合は、コード全体をチャット欄にコピーしてください