

予測モデル

川田恵介 (keisukekawata@iss.u-tokyo.ac.jp)

2026-09-16

1 予測問題

1.1 目標

- OLS を学ぶことで、「データをモデルに要約する」をイメージとして掴む
 - ▶ 予測モデルとして用いる
- 予測モデルの評価法を学ぶ

1.2 3つのタスク

- 研究目標: 社会について、知りたいことを決める
- 推定目標: 母集団 について、知りたいことを決める
- 推定方法: データ の活用方法を決める

1.3 実習例: 研究目標

- 不動産会社にて、次々に持ち込まれる中古マンションの価格査定業務支援が検討されている
 - ▶ 当該物件の市場価格だが、マンションの持つさまざまな背景変数(広さ、立地、築年数等)によって異なるため、十分な経験がないと算出困難
- 研究目標: 取引価格を予測する”AI” (予測モデル) を構築

1.4 予測

- 日常的な予測: 自身が経験した/見聞きした事例の傾向から、なんとなく予想する
 - ▶ 港区の広い物件は、高い価格である傾向等
- 汎用 AI による予測: プロンプトに背景変数を打ち込めば予測してくれる
 - ▶ 様々なデータから推定された Blackbox モデルであり、関心となる市場について予測精度が高いとは限らない

1.5 自社データに基づく予測

- 日常業務の中で業務データが蓄積可能
 - ▶ 国土交通省も提供 不動産情報ライブラリ
- 関心となる市場について、より透明性の高い方法でモデルが推定できる

1.6 データ

```
library(tidyverse)

df <- nanoparquet::read_parquet("Public/example.pq")

head(df)
```

```
# A data frame: 6 × 7
  price  size tenure district distance reform  year
* <dbl> <dbl> <dbl> <chr>      <dbl> <dbl> <dbl>
1    59    45    11 千代田区         2      0      0
2   120    55     2 千代田区         4      0      0
3    65    45     9 千代田区         3      0      0
4    45    35    20 千代田区         3      0      0
5    21    30    42 千代田区         2      0      0
6    30    45    48 千代田区         4      0      0
```


- price: 取引価格, year: 取引年 (2026 年なら 1, 2025 年なら 0), size: 部屋の広さ, tenure: 築年数, district: 立地, distance: 駅からの距離, reform: 改築の有無

2 予測モデル

2.1 単純な予測モデル

- size のみから取引価格を予測するモデルを推定する
 - ▶ 予測モデル = size を入力すれば、予測取引価格を自動計算してくれる式

2.2 部屋の広さと取引価格の傾向




2.3 情報の要約

- 全く同じ size でも、price は大きく異なる
 - ▶ size 以外の要因が price を左右
 - 最大値を予測価格とすると、他の要因が上振れた事例から予測しており、一般に不適切
- 代表的な方法は(条件付き)平均値

$$\text{size ごとに } \frac{\text{総取引額}}{\text{事例数}}$$

2.4 部屋の広さと平均取引価格の傾向



2.5 事例数の問題

- データの中に、size, tenure, district, distance, reform, year の組み合わせは、10033 個ある
 - ▶ 事例数は 10828 なので、ほとんど組み合わせは 1 事例しかない

2.6 小規模事例の平均

- 平均値の計算に用いる事例が少なければ、観察できない要因の上振れ/下振れの影響を受けやすい
- 例: 岩手県水沢市出身 31 歳男性の事例は、大谷翔平選手のみ
 - ▶ 岩手県水沢市出身 31 歳男性の運動能力の平均値
 - ▶ $\simeq$ 大谷翔平選手の運動能力...?

2.7 モデル化

- データの特徴を”大雑把に”捉える
- 代表例は線型モデル

$$\text{price} \simeq \beta_0 + \beta_1 \times \text{size} + ..$$

- 極力データに適合するように、 β の値を選ぶ

2.8 例

```
lm(price ~ size, df)
```


```
Call:
lm(formula = price ~ size, data = df)
```

```
Coefficients:
(Intercept)      size
   -28.191      1.736
```

- size = 50 の物件の予測取引価格は、

$$-28.191 + 1.736 \times \underbrace{size}_{=50} \simeq 58.609$$

2.9 例



2.10 最小二乗法

- ここまで最小二乗法 (OLS) を用いて、極力データに適合するモデルを算出
- 以下が最も小さくなる β を算出する:

$$(price - \text{予測値})^2 \text{ の総和}$$

2.11 曲線モデル

- 直線以外を当てはめることも容易

$$\text{price} \simeq \beta_0 + \beta_1 \times \text{size} + \beta_2 \times \text{size}^2$$

2.12 例

```
lm(price ~ poly(size,2), df)
```


Call:

```
lm(formula = price ~ poly(size, 2), data = df)
```

Coefficients:

(Intercept)	poly(size, 2)1	poly(size, 2)2
73.8	3780.7	1023.9

2.13 例



2.14 重回帰

- 複数の変数も容易に導入できる

$$\text{price} \simeq \beta_0 + \beta_1 \text{size} + \beta_2 \text{千代田} + \dots$$

- 千代田: 千代田区であれば 1、それ以外であれば 0

2.15 例

```
lm(price ~ size + tenure + distance + district, df)
```

Call:

```
lm(formula = price ~ size + tenure + distance + district, data = df)
```

Coefficients:

(Intercept)	size	tenure	distance
14.787	1.764	-1.238	-2.133
district中央区	district中野区	district北区	district千代田区
25.977	-2.620	-25.153	41.195
district台東区	district品川区	district大田区	district文京区
-5.425	13.921	-16.614	13.806
district新宿区	district杉並区	district板橋区	district江戸川区
13.388	-5.004	-24.834	-38.123
district江東区	district渋谷区	district港区	district目黒区
-8.293	44.756	68.339	23.733
district練馬区	district荒川区	district葛飾区	district豊島区
-22.063	-25.858	-33.045	6.450
district足立区	district墨田区		
-36.819	-12.135		

2.16 例

```
model <- lm(price ~ ., df)
```

```
df$pred <- predict(model, df)
```

2.17 例: 高額物件

```
arrange(df, -pred)
```

A data frame: 10,828 × 8

	price	size	tenure	district	distance	reform	year	pred
	<dbl>	<dbl>	<dbl>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	950	130	1	港区	5	0	1	306.
2	1200	130	2	港区	7	0	1	300.
3	490	125	3	港区	6	0	1	292.
4	550	120	1	港区	4	0	1	290.
5	520	125	5	港区	8	0	1	285.
6	900	130	10	港区	6	0	0	282.
7	720	130	11	港区	6	0	0	281.
8	710	125	18	港区	5	0	1	276.
9	730	125	3	渋谷区	4	0	1	273.

```
10  500  115      2  港区          3      0      0  272.
# i 10,818 more rows
```


2.18 例: 低額物件

```
arrange(df, pred)
```

```
# A data frame: 10,828 × 8
  price size tenure district distance reform year pred
  <dbl> <dbl> <dbl> <chr>      <dbl> <dbl> <dbl> <dbl>
1   5.8   25     50  足立区         22      0      0 -92.1
2    6    20     37  足立区         26      0      1 -83.4
3   6.5   25     49  江戸川区        12      0      0 -70.5
4   11    25     49  江戸川区        11      0      0 -68.3
5   6.7   30     55  江戸川区        16      0      1 -67.9
6   8.9   25     48  江戸川区        11      0      0 -67.1
7    8    35     55  足立区         14      0      0 -63.6
8   8.9   25     48  江戸川区         9      0      0 -62.8
9   13    30     49  足立区         13      0      0 -62.8
10  10    25     48  江戸川区         8      0      0 -60.7
# i 10,818 more rows
```

2.19 Takeaway

- 研究者が指定したモデルに、大量の属性情報を集約する
 - OLS は、データに当てはまるようにモデルを推定する
 - 性能の良いモデルであれば、実務に実装できる



3 予測モデルの性能評価

3.1 推定と評価

- 予測モデルは、どの程度機能するのか?
 - 実務上極めて重要
- 事後評価: 実際に実装し業務に活用しながら、確かめる
 - 予測失敗の被害が軽微な場合は活用可能

3.2 事後評価

1. 予測モデルを推定
2. 実際の事例に応用し、実際の価格と予測価格を新規に収集
3. 実際と予測価格の乖離を測定: 典型的には

(実際の価格 - 予測価格)²の平均

3.3 事前評価

- 実務に実装する前に、その予測精度を測定したい
- 課題は、
 - ▶ 予測の評価に用いるための、新規の事例が存在しない

3.4 不適切な事前評価

- データから都合のいい事例だけを探すと、高い精度の指標が当然出せる
 - ▶ ただの不正なので厳禁
- 例: model について、予測誤差が”5 千円”以下になる事例がある

```
# A data frame: 6 × 8
  price  size tenure district distance reform  year  pred
<dbl> <dbl> <dbl> <chr>      <dbl> <dbl> <dbl> <dbl>
1    15    20    42  文京区         1     0     1  15.0
2   130    90    22  江東区         7     1     1 130.
3   110    40    15  渋谷区         3     0     1 110.
4   110    40    15  渋谷区         3     0     1 110.
5    49    60    20  足立区         7     0     1  49.0
6    39    70    25  葛飾区        14     0     0  39.0
```

3.5 不適切な事前評価

- 「モデルを推定した事例を、テストにも再利用」したくなるが、一般には避ける必要がある
 - ▶ 少ない事例で、複雑なモデルを推定すると適合度が過度に高くなってしまう

3.6 例

```
small <- df[1:2,] # 2事例を抜き出す

model <- lm(price ~ size, small)

small$pred <- predict(model, small)

small
```

```
# A data frame: 2 × 8
  price  size tenure district distance reform  year  pred
* <dbl> <dbl> <dbl> <chr>      <dbl>  <dbl> <dbl> <dbl>
1    59   45    11 千代田区         2      0      0    59
2   120   55      2 千代田区         4      0      0   120
```

3.7 例


- 他の事例については、予測を大きく外している

```
# A data frame: 6 × 8
  price  size tenure district distance reform  year  pred
* <dbl> <dbl> <dbl> <chr>      <dbl>  <dbl> <dbl> <dbl>
1    59   45    11 千代田区         2      0      0    59
2   120   55      2 千代田区         4      0      0   120
3    65   45      9 千代田区         3      0      0    59
4    45   35    20 千代田区         3      0      0   -2.00
5    21   30    42 千代田区         2      0      0  -32.5
6    30   45    48 千代田区         4      0      0    59
```


3.8 直感

- モデルは、データに極力当てはまるように推定される
 - ▶ モデルを評価する上で、“都合がいいデータ”


3.9 直感



3.10 直感



3.11 余談: “インチキ”自己啓発本



3.12 余談: 就活の練習

- “ChatGPT”を活用して面接やケースの練習 (想定問答) を行う
- ChatGPT からのフィードバックを用いて、“妥当な回答を予測する脳内モデル”が推定されるので
 - ▶ ChatGPT 相手には、完璧に回答できるようになる
 - ▶ 人間相手の本番では?
 - 他の AI や友達相手に力試しする必要がある

3.13 Takeaway

- データの持つ煩雑な情報をモデルに集約し、予測に活用

- ▶ 理論的にも望ましい性質を持つ(次回)
- モデルの予測性能を評価するためには、新しい事例が必要
 - ▶ 典型的なアプローチは、事前にデータを分割する

3.14 Takeaway: 推奨される事前評価

- データを2分割 (訓練/テスト) にランダム分割する
 - ▶ 訓練: 予測モデルを推定する
 - ▶ テスト: 予測性能を評価する
- まぐれあたりによる過大/過小評価を避けるために、テストにも十分な事例数を割く必要がある
 - ▶ 典型的には2割程度をテストに配分する

3.15 実例

```
set.seed(11)

group <- rsample::initial_split(
  df
)

train <- rsample::training(group)

test <- rsample::testing(group)
```

3.16 実例

```
model <- lm(
  price ~ size,
  train) # OLSモデルの推定

model_long <- lm(
  price ~ .,
  train) # OLSモデルの推定

mean((test$price - predict(model,test))^2) # OLSのテスト
```

```
[1] 2298.022
```

```
mean((test$price - predict(model_long,test))^2) # OLSのテスト
```

[1] 1070.129