

LASSO

機械学習

川田恵介
東京大学
keisukekawata@iss.u-tokyo.ac.jp

2025-09-23

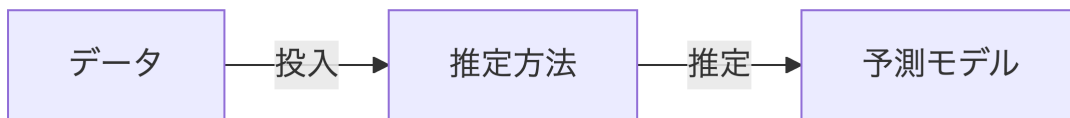
1 LASSO

1.1 目標

- データ主導の線型モデルの推定方法を学ぶ
 - 代表的な手法である LASSO を紹介
- “モデルの複雑性を調整する”というイメージを把握する

1.2 復習

- 予測モデルの構築: データをモデルに変換する
 - 変換 = 推定/学習
- 変換手順は、人間が決める必要がある
 - 変換手順 = 定式化と推定方法/アルゴリズム



1.3 定式化の例: ベンチマーク

- $Price \simeq \beta_0 + \beta_1 \times \underbrace{RoomNumber}_{\text{部屋数}}$

1.4 定式化の例: より単純なモデル

- $Price \simeq \beta_0$
 - $\beta_1 = 0$ と “人間” が決めている → データに決めさせる部分が減っている
 - $\beta_0 = Price$ の単純平均 (東京全体での平均価格) が予測 “モデル” となる

1.5 定式化の例: より複雑なモデル

- $Price \simeq \beta_0 + \beta_1 \times RoomNumber + \beta_2 \times RoomNumber^2 + \beta_3 \times RoomNumber^3$

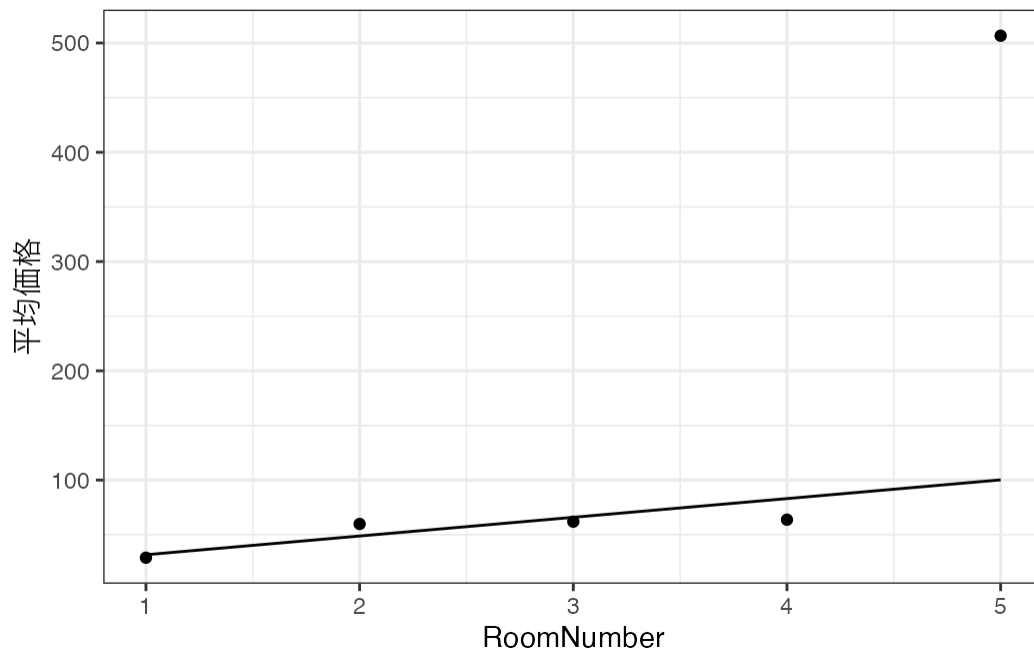
- $\beta_2 = \beta_3 = 0$ と”人間”が決れば、ベースモデルと一致
 - より多くをデータに決定させる定式化

1.6 定式化の例: 凄く複雑なモデル

- $Price \simeq \beta_0 + \beta_1 \times RoomNumber + \beta_2 \times RoomNumber^2 + \beta_3 \times RoomNumber^3 + \beta_4 \times RoomNumber^4$


- $\beta_4 = 0$ と”人間”が決れば、より複雑なモデルと一致

1.7 例: ベンチマーク




- 5 部屋物件の予測価格 $\simeq 100$

1.8 例: 単純なモデル




- 5 部屋物件の予測価格 ≈ 45

1.9 例: 複雑なモデル



- 5 部屋物件の予測価格 ≈ 191

1.10 例: 凄く複雑なモデル



- 5 部屋物件の予測価格 ≈ 507

1.11 過剰適合/過学習

- 複雑なモデルは、より多くをデータが決定し、データ上の平均値とモデルが完全一致している
 - ▶ データに最も適合するが、、
 - 予測性能が低いケースが多い
- **過学習/過剰適合:** モデルが、データと過度に適合する(事例から過度に学び過ぎてしまう)現象
 - ▶ 非常に少数の事例から生じたデータ特徴も、モデルに反映してしまう
 - 5 部屋の物件は 3 事例しか存在しない

2 複雑性への罰則

2.1 目標

- データにより多くのことを決めさせるには、複雑なモデルを推定する必要がある
 - ▶ 複雑なモデルを OLS 推定すると、データへの過剰適合が生じる
- 複雑なモデルを「データに程よく適合させたい」

2.2 例え話

- 入門経済学: 生産方法を企業の自主的な意思決定に任せると
 - ▶ 同じ生産量を達成する方法の中で、最も費用が少ない方法が選ばれる
 - 希少な資源の利用を減らせ、それなりに望ましい
 - ▶ 一般に”負の外部性”が生じる
 - 温室効果ガスの過剰排出等
 - ▶ 社会的に望ましい水準に誘導するための政策が必要
 - 総量規制、環境税、補助金等

2.3 罰則付き回帰

- 線型モデル $Y \simeq \beta_0 + \beta_1 X_1 + \dots$ を推定
- 以下を最小にするように β を推定

$$\underbrace{\text{データへの不適合度}}_{(Y - \text{予測値})^2 \text{ のデータ上の平均}} + \text{複雑性への罰則}$$

2.4 OLS の再解釈

- OLS: 以下を最小にするように推定

データへの不適合度

- 定式化を前提に、データへの適合のみを目指す推定方法
 - ▶ 過剰適合の原因

2.5 罰則の定式化

- $$\text{複雑性への罰則} = \underbrace{\lambda}_{\text{税率}} \times \text{複雑性の測定値}$$
 - ▶ LASSO においては、
$$\text{複雑性の測定値} = |\beta_1| + |\beta_2| + \dots$$
- λ は予測性能が良くなりそうな値を設定する
 - ▶ いろいろな方法が提案されている
 - ▶ 本講義では、hdm package で実装されている理論的指標を用いる

2.6 λ の影響

- 最も単純なモデル (複雑性の測定値 = 0) は、

$$\beta_1 = \beta_2 = \dots = 0$$

- ▶ $Y \simeq \beta_0 =$ 単純平均
- $|\beta_1|$ が大きくなれば、予測値が X_1 により反応する
 - ▶ より複雑な予測モデル

2.7 λ の影響

- $\lambda \rightarrow \infty$ であれば、複雑性の低下が最優先
 - ▶ $\beta_1 = \beta_2 = \dots = 0$
 - ▶ 予測モデル = 単純平均

2.8 λ の影響

- $\lambda = 0$ であれば、データへの当てはまりのみを追求
 - ▶ OLS!!!
 - ▶ 予測モデル = OLS で推定されたモデル

2.9 例

```
hdm::rlasso(Price ~ Size + Tenure + Distance + District, data, post = FALSE)
```

Call:

```
rlasso.formula(formula = Price ~ Size + Tenure + Distance + District,
  data = data, post = FALSE)
```

Coefficients:

(Intercept)	Size	Tenure	Distance
15.2453	1.1703	-0.6395	-0.9943
District中央区	District中野区	District北区	District千代田区
2.8331	0.0000	-13.0874	18.3989
District台東区	District品川区	District大田区	District文京区
-4.2591	0.6435	-8.3461	0.3467
District新宿区	District杉並区	District板橋区	District江戸川区
3.4565	0.0000	-15.6118	-26.6841
District江東区	District渋谷区	District港区	District目黒区
-9.8651	15.1645	32.4377	8.7597
District練馬区	District荒川区	District葛飾区	District豊島区
-15.0456	-18.2211	-22.4133	-0.7486
District足立区	District墨田区		
-23.5088	-9.4562		

2.10 例: OLS


```
lm(Price ~ Size + Tenure + Distance + District, data)
```

Call:
`lm(formula = Price ~ Size + Tenure + Distance + District, data = data)`

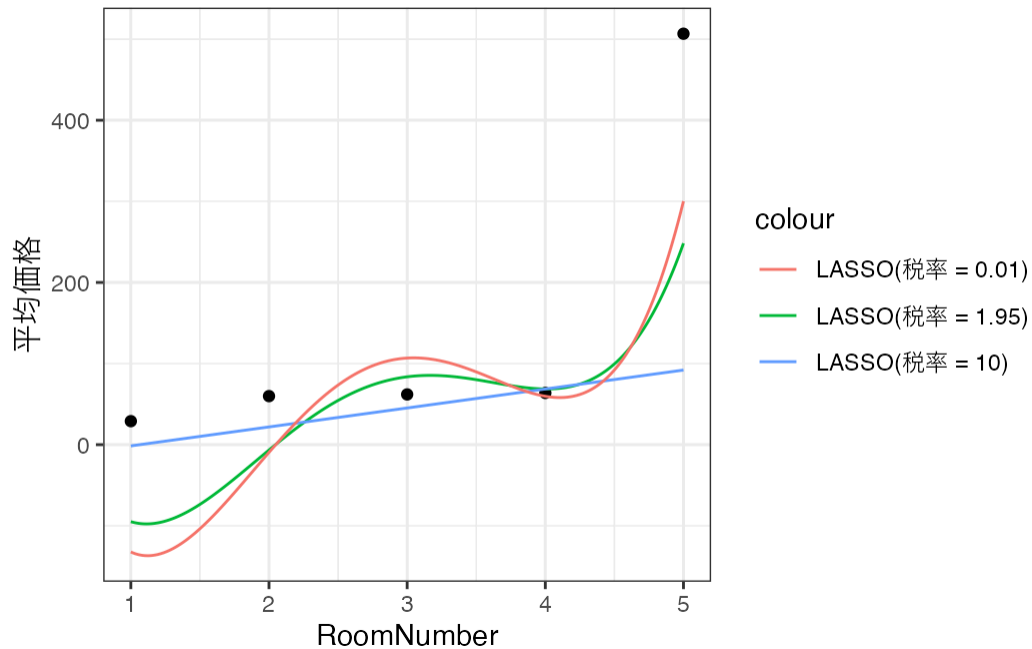
Coefficients:

(Intercept)	Size	Tenure	Distance
9.9762	1.2373	-0.6782	-1.0522
District中央区	District中野区	District北区	District千代田区
7.4307	2.1518	-11.3431	28.5354
District台東区	District品川区	District大田区	District文京区
-2.3232	5.8732	-5.3455	5.4088
District新宿区	District杉並区	District板橋区	District江戸川区
8.6121	1.7546	-13.2401	-25.5362
District江東区	District渋谷区	District港区	District目黒区
-8.0226	24.2997	41.3445	15.7670
District練馬区	District荒川区	District葛飾区	District豊島区
-12.8446	-16.9899	-20.9135	1.7057
District足立区	District墨田区		
-21.9901	-6.8787		

2.11 例



2.12 例



2.13 LASSO の性質: 変数選択

- LASSO の重要な性質は変数選択

- ▶ モデルから変数を除外する

- 例: モデル

$$Price \simeq \beta_0 + \beta_1 Size + \beta_2 Tenure$$

から、Tenure を除外する

- ▶ $Price \simeq \beta_0 + \beta_1 Size + \underbrace{\beta_2}_{=0} Tenure$

2.14 LASSO の性質

- 罰則の定式化より、 β の推定値が厳密に 0 となりうる
 - ▶ 該当する変数が除外される
- OLS など他の推定方法では、一般に厳密に 0 とはならない
 - ▶ 変数が除外されない
 - 除外したいのであれば、人間が推定前に除外しないとイケない
- LASSO は、“データ主導の変数選択”を行う

2.15 Takeaway

- 一般に、OLS は複雑なモデルの推定が苦手
 - ▶ 過剰適合を避けるために、多くの事例数を要求
 - 経験則として、 β の数が事例数の $1/3$ を超えると予測性能が悪化しやすい
- 機械学習 = 複雑なモデルを、過剰適合を避けながら推定する方法を提案
 - ▶ LASSO は代表格