

LASSO

川田恵介 (keisukekawata@iss.u-tokyo.ac.jp)

2026-09-22

1 モデル複雑化

1.1 目標

- データ主導の線型モデルの推定方法を学ぶ
 - 代表的な手法である LASSO を紹介
- “モデルの複雑性を調整する”というイメージを把握する

1.2 復習

- 予測モデルの構築: データをモデルに変換する
 - 変換 = 推定/学習
- 変換手順は、人間が決める必要がある
 - 変換手順 = 定式化と推定方法/アルゴリズム



1.3 定式化の例: ベンチマーク

- $price \simeq \beta_0 + \beta_1 \times size$


1.4 定式化の例: より複雑なモデル

- $price \simeq \beta_0 + \beta_1 \times size + \beta_2 \times size^2$
- $\beta_2 = 0$ と”人間”が決れば、ベースモデルと一致
 - より多くをデータに決定させる定式化

1.5 定式化の例: 凄く複雑なモデル


- $price \simeq \beta_0 + \beta_1 \times size + \dots + \beta_{18} \times size^{18}$

1.6 例: ベンチマーク




- 125 平米物件の予測価格 $\approx$ 2 億円

1.7 例: 複雑なモデル



- 125 平米物件の予測価格 $\approx$ 2 億 5000 万円

1.8 例: 凄く複雑なモデル



- 125 平米物件の予測価格 $\approx$ 3 億円

1.9 単純なモデルの弊害

- 「一直線」や「単純な曲線」を平均値に当てはめる
 - ▶ 価格の持つ複雑な特徴を捉えられない

1.10 過剰適合/過学習

- 複雑なモデルは、データ上の平均値とモデルに接近している
 - ▶ データに最も適合するが、、
 - 予測性能が低いケースが多い (後述)
- **過学習/過剰適合:** モデルが、データと過度に適合する(ハズレ値から過度に学び過ぎてしまう)現象
 - ▶ 非常に少数の事例から生じたデータ特徴も、モデルに反映してしまう

2 複雑性への罰則

2.1 目標

- データにより多くのことを決めさせるには、複雑なモデルを推定する必要がある
 - ▶ 複雑なモデルを OLS 推定すると、データへの過剰適合が生じる

- 複雑なモデルを「データに程よく適合させたい」

2.2 罰則付き回帰

- 線型モデル $Y \simeq \beta_0 + \beta_1 X_1 + \dots$ を推定
- 以下を最小にするように β を推定

$$\underbrace{\text{データへの不適合度}}_{(Y - \text{予測値})^2 \text{ のデータ上の平均}} + \text{複雑性への罰則}$$

2.3 例え話: 入門経済学

- 生産方法を企業の自主的な意思決定に任せると
 - ▶ 同じ生産量を達成する方法の中で、最も費用が少ない方法が選ばれる
 - 希少な資源の利用を減らせ、概ね望ましい
 - ▶ 一般に”負の外部性”が生じる
 - 温室効果ガスの過剰排出等
 - ▶ 社会的に望ましい水準に誘導する政策が必要
 - 環境税、補助金等

2.4 OLS の再解釈

- OLS: 以下を最小にするように推定

$$\text{データへの不適合度}$$
- 定式化を前提に、データへの適合のみを目指す推定方法
 - ▶ 過剰適合の原因

2.5 罰則の定式化

- $\text{複雑性への罰則} = \underbrace{\lambda}_{\text{税率}} \times \text{複雑性の測定値}$
 - ▶ LASSO においては、

$$\text{複雑性の測定値} = |\beta_1| + |\beta_2| + \dots$$
- λ は予測性能が良くなりそうな値を設定する
 - ▶ いろいろな方法が提案されている
 - ▶ 本講義では、hdm package で実装されている理論的指標を用いる

2.6 例: LASSO

```
hdm::rlasso(price ~ poly(size, 18), data, post = FALSE)
```

Call:

```
rlasso.formula(formula = price ~ poly(size, 18), data = data,  
  post = FALSE)
```

Coefficients:

(Intercept)	poly(size, 18)1	poly(size, 18)2	poly(size, 18)3
73.8	3630.5	765.0	323.0
poly(size, 18)4	poly(size, 18)5	poly(size, 18)6	poly(size, 18)7
0.0	0.0	0.0	0.0
poly(size, 18)8	poly(size, 18)9	poly(size, 18)10	poly(size, 18)11
0.0	0.0	0.0	0.0
poly(size, 18)12	poly(size, 18)13	poly(size, 18)14	poly(size, 18)15
0.0	0.0	0.0	0.0
poly(size, 18)16	poly(size, 18)17	poly(size, 18)18	
0.0	0.0	0.0	

2.7 例: OLS

```
lm(price ~ poly(size, 18), data)
```


Call:

```
lm(formula = price ~ poly(size, 18), data = data)
```

Coefficients:

(Intercept)	poly(size, 18)1	poly(size, 18)2	poly(size, 18)3
73.8040	3780.7449	1023.9015	602.4612
poly(size, 18)4	poly(size, 18)5	poly(size, 18)6	poly(size, 18)7
175.6637	95.7909	191.4587	175.9260
poly(size, 18)8	poly(size, 18)9	poly(size, 18)10	poly(size, 18)11
46.8914	-64.8858	6.1570	73.8576
poly(size, 18)12	poly(size, 18)13	poly(size, 18)14	poly(size, 18)15
-85.6087	-98.8028	99.8428	14.2541
poly(size, 18)16	poly(size, 18)17	poly(size, 18)18	
0.8678	97.4490	-35.7411	

2.8 例



2.9 例: LASSO

```
hdm::rlasso(price ~ size + tenure + district + distance, data, post = FALSE)
```

Call:

```
rlasso.formula(formula = price ~ size + tenure + district + distance,
  data = data, post = FALSE)
```

Coefficients:

(Intercept)	size	tenure	district中央区
22.962	1.686	-1.217	19.594
district中野区	district北区	district千代田区	district台東区
-5.043	-27.237	28.370	-8.411
district品川区	district大田区	district文京区	district新宿区
6.951	-19.603	6.559	6.533
district杉並区	district板橋区	district江戸川区	district江東区
-7.620	-27.723	-39.805	-10.659
district渋谷区	district港区	district目黒区	district練馬区
34.416	58.181	16.563	-24.680
district荒川区	district葛飾区	district豊島区	district足立区
-27.489	-35.165	0.000	-38.898
district墨田区	distance		
-14.939	-2.083		

2.10 例: OLS

```
lm(price ~ size + tenure + district + distance, data)
```

Call:

```
lm(formula = price ~ size + tenure + district + distance, data = data)
```

Coefficients:

(Intercept)	size	tenure	district中央区
14.787	1.764	-1.238	25.977
district中野区	district北区	district千代田区	district台東区
-2.620	-25.153	41.195	-5.425
district品川区	district大田区	district文京区	district新宿区
13.921	-16.614	13.806	13.388
district杉並区	district板橋区	district江戸川区	district江東区
-5.004	-24.834	-38.123	-8.293
district渋谷区	district港区	district目黒区	district練馬区
44.756	68.339	23.733	-22.063
district荒川区	district葛飾区	district豊島区	district足立区
-25.858	-33.045	6.450	-36.819
district墨田区	distance		
-12.135	-2.133		

2.11 λ の影響

- 最も単純なモデル (複雑性の測定値 = 0)は、

$$\beta_1 = \beta_2 = \dots = 0$$

- ▶ $Y \simeq \beta_0$ = 単純平均
- $|\beta_1|$ が大きくなれば、予測値が X_1 により反応する
 - ▶ より複雑な予測モデル

2.12 λ の影響

- $\lambda \rightarrow \infty$ であれば、複雑性の低下が最優先
 - ▶ $\beta_1 = \beta_2 = \dots = 0$
 - ▶ 予測モデル = 単純平均

2.13 λ の影響

- $\lambda = 0$ であれば、データへの当てはまりのみを追求
 - ▶ OLS!!!
 - ▶ 予測モデル = OLS で推定されたモデル

2.14 LASSO の性質: 変数選択

- LASSO の重要な性質は変数選択
 - ▶ モデルから変数を除外する
- 例: モデル

$$price \simeq \beta_0 + \beta_1 size + \beta_2 tenure$$

から、Tenure を除外する

$$\text{▶ } price \simeq \beta_0 + \beta_1 size + \underbrace{\beta_2}_{=0} tenure$$

2.15 LASSO の性質

- 罰則の定式化より、 β の推定値が厳密に 0 となりうる
 - ▶ 該当する変数が除外される
- OLS など他の推定方法では、一般に厳密に 0 とはならない
 - ▶ 変数が除外されない
 - 除外したいのであれば、人間が推定前に除外しないといけない
- LASSO は、“データ主導の変数選択”を行う

2.16 Takeaway

- 一般に、OLS は複雑なモデルの推定が苦手
 - ▶ 過剰適合を避けるために、多くの事例数を要求
 - 経験則として、 β の数が事例数の 1/3 を超えると予測性能が悪化しやすい
- 機械学習 = 複雑なモデルを、過剰適合を避けながら推定する方法を提案
 - ▶ LASSO は代表格