ここまでの復習

経済学のための機械学習入門

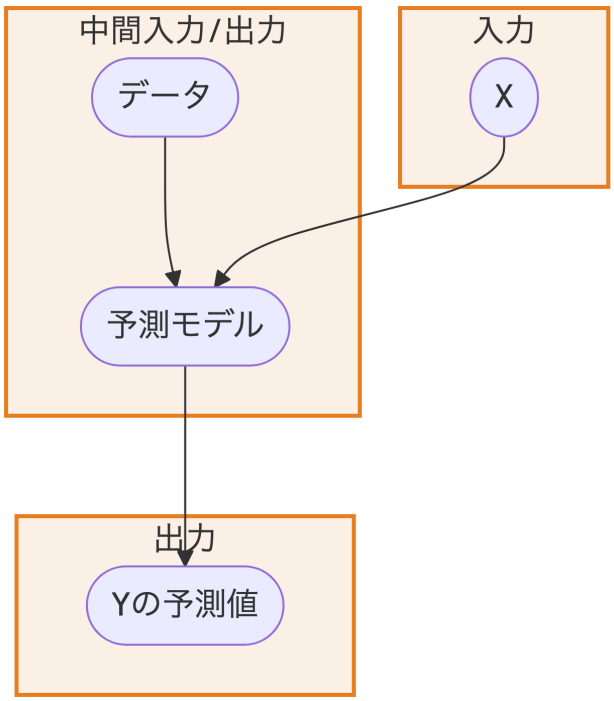
川田恵介

keisukekawata@iss.u-tokyo.ac.jp

2026-10-20

1 母集団と抽出

1.1 ここまでの議論



1.2 根本的な課題

- 予測: データに含まれていない事例を予測する
  - データのみでは、データの特徴しか議論できない
  - 矛盾

1.3 統計的枠組みの必要性

- 「データと予測対象の間の関係性」という抽象度の高い議論が必要
  - 議論の枠組み (論点整理) を明示することが重要
- 最も代表的な枠組みは、「母集団と抽出」[1]

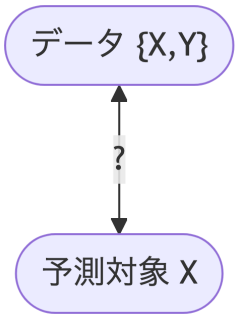
1.4 母集団と抽出

- **母集団**: 無限大の事例数を持つ仮想的なデータ
  - 本講義では変数は手元のデータと同じ
- データの事例と予測対象は、何らかの母集団から抽出されている

1.5 ランダム抽出

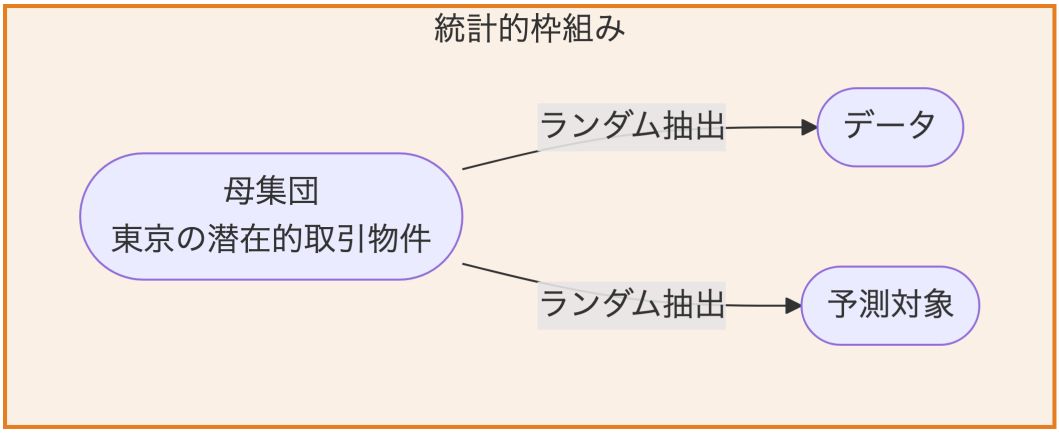
- 重要な仮定は以下
  - データの事例と予測対象は同じ母集団から抽出
  - どの事例が母集団から選ばれるかは、完全ランダム
    - ランダム抽出

1.6 イメージ

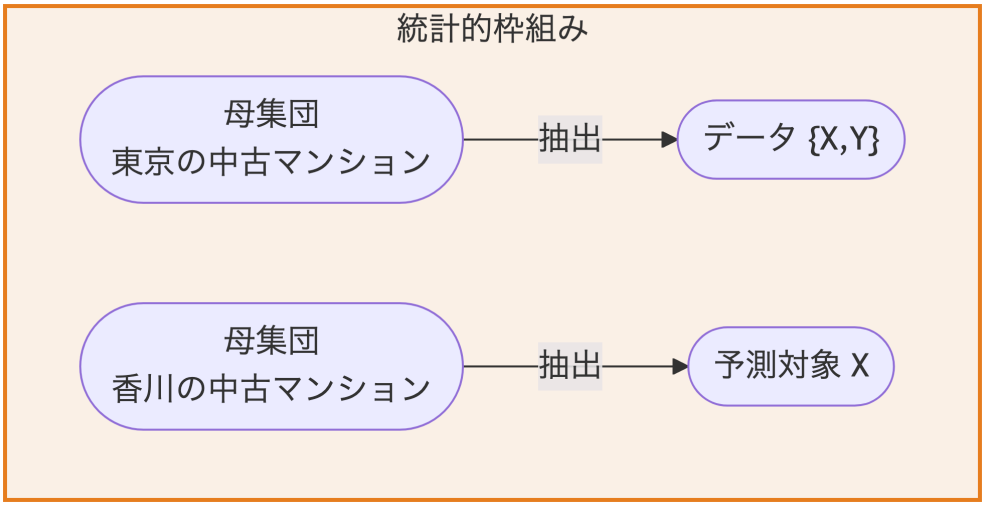


1.7 イメージ

[1] 頻度論と呼ばれる枠組みです。代替的なものとしては、ベイズ論があります。



1.8 想定しない状況



1.9 実践上のイメージ

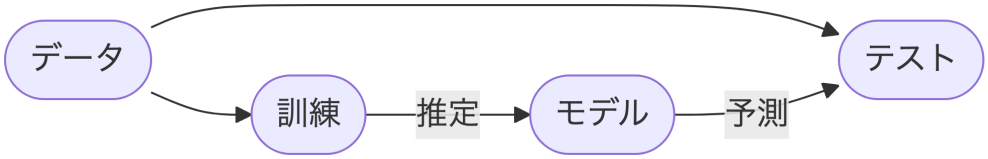
- データを収集した「社会」と予測する「社会」が、同じような特徴を持つ
  - 地理的、時間的に近い
  - 反例: アメリカの消費者データから、ピーナッツバターの消費量を予測するモデルを推定し、日本に適用する

1.10 理論的性質

- データも予測対象も同じ母集団からランダム抽出されているのであれば
  - 理想の予測モデル (平均二乗誤差を最小化) は、母集団における平均値 (母平均) $E[Y \mid X]$
    - 広さ 20 の物件についての理想の予測

$$= E[price \mid size = 20]$$

1.11 データ活用のアイディア



1.12 理論的性質: 予測モデル

- 訓練データの事例数が十分あれば、各 X ごとに Y の母平均を推定すればよい
  - 根拠: 事例数が無限大 + ランダム抽出であれば、データ上の Y の平均値は母平均 $E[Y \mid X]$ と一致する[2]
- 現実には事例数は不十分な場合が多いので、モデルで近似する

1.13 例

- 母平均とデータ上の平均とモデルを並列する図を挿入

1.14 理論的性質: 評価

- テストデータの事例数が比較的少ない場合でも、平均予測誤差 $(Y - \text{予測値の母平均})^2$ は、テストデータ上での平均値と類似する
  - テストデータ上での平均値を予測性能の指標とすることが一般的

2 Prediction interval

2.1 点しての予測の問題点

- 予測モデルは予測を特定の数値 (点) として出力する
  - どれだけ巨大な訓練データで予測モデルを推定しても、実際の値と乖離する
- 練習問題: なぜ?

2.2 妥当な推論

- 妥当な推論: 「前提が真であれば、結論は真である」が保証された推論 (ロジック)
- R 関数の比喩: バグがない関数
  - 「入力 (前提) が正しければ、出力 (結論)は正しい」
  - 「一見うまく機能している関数であっても、バグがあれば使いたくない」

[2] 一致性(Consistency)

2.3 点しての予測の問題点

- 「データと予測目標が同じ母集団からランダム抽出され、無限大の事例数を持つ」という非現実的な前提を受け入れたとしても
  - 「予測は当たる」という結論の正しさは保証できない

2.4 予測区間

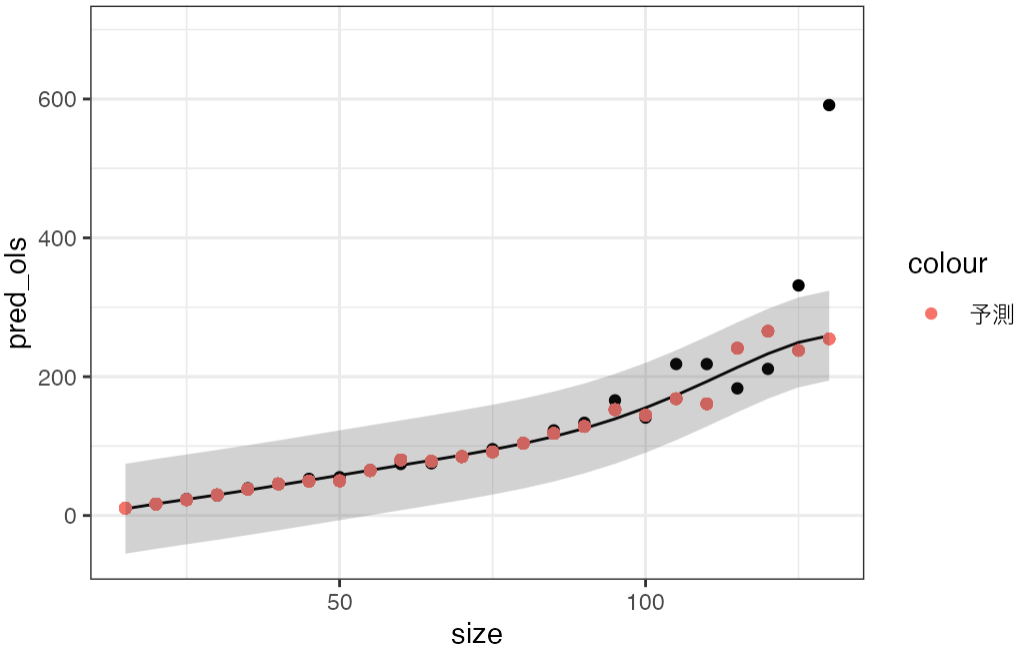
- **予測区間**: “予測対象の Y を一定確率 (α) で含む区間”
  - データと予測目標が同じ母集団からランダム抽出されるならば
  - 予測区間は”概ね”当たる
- さまざまな導出方法が提案されてきた
  - 本スライドでは Conformal interval を紹介

2.5 計算方法

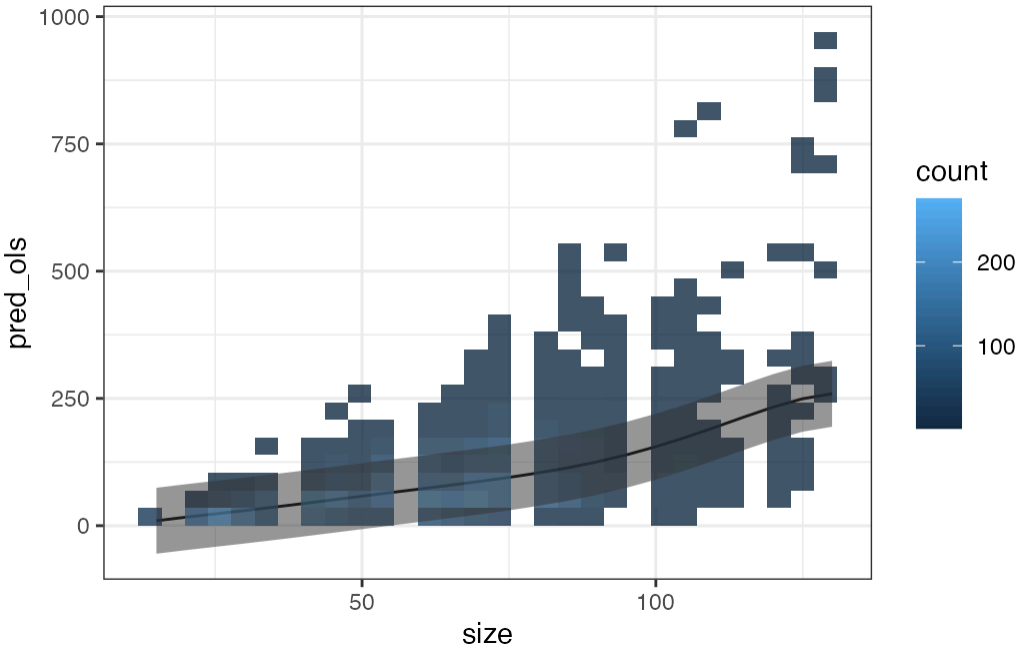
1. **訓練データ**から、(何らかの方法で)予測モデルを推定
2. **テストデータ**から、事前に決めた α に対応するスコア (予測誤差の絶対値; $|Y -$ 予測値$|$) を計算
3. スコアの α[3] 分位点 (q) を計算
4. 予測区間: [予測値 $- q$, 予測値 $+ q$] を計算

[3] 厳密には $\frac{1+n}{n}\alpha$

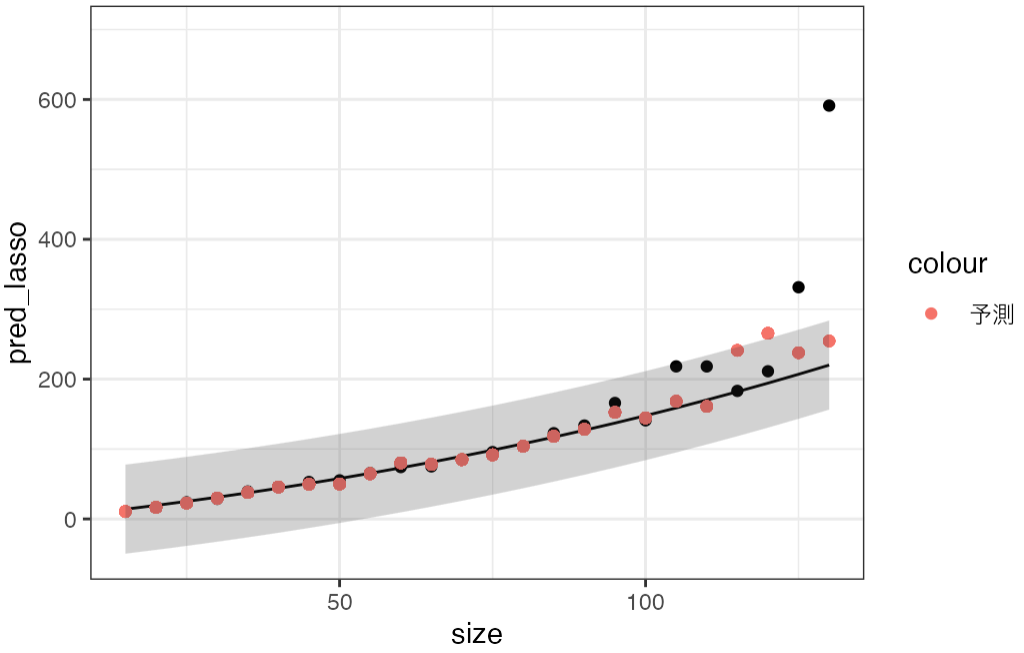
2.6 例


600
400
200
0
pred_ols
50
100
size
colour
予測

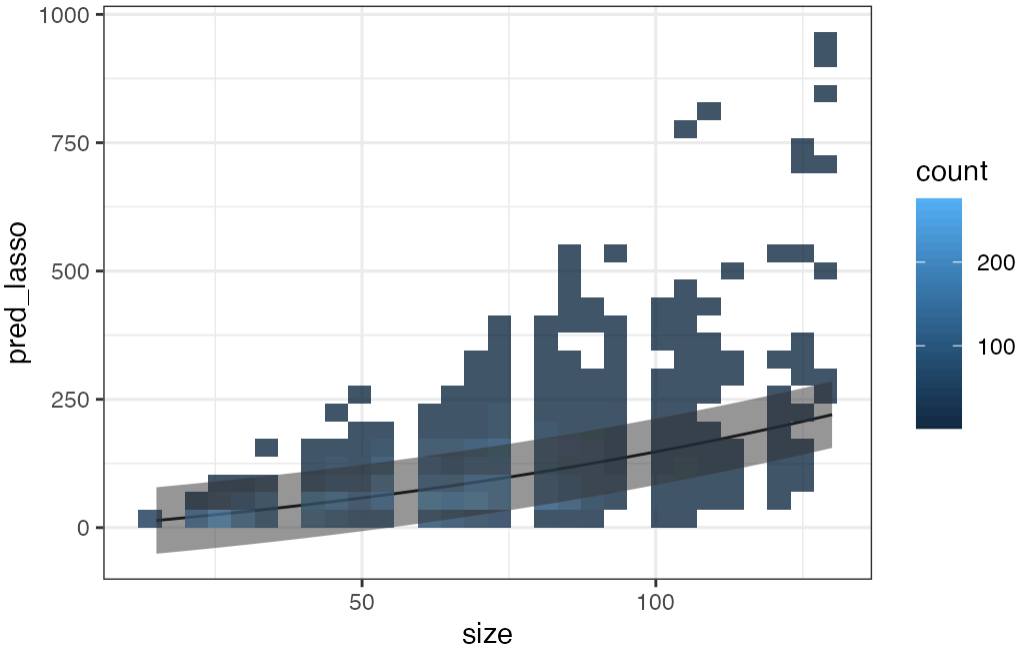
2.7 例


1000
750
500
250
0
pred_ols
50
100
size
count
200
100

2.8 例


600
400
200
0
pred_lasso
50
100
size
colour
予測

2.9 例


1000
750
500
250
0
pred_lasso
50
100
size
count
200
100

2.10 区間の性質

- **Calibration データで条件づけない場合:** “任意の事例数”について、予測対象を $1-\alpha$ で含む
  - 後で信頼区間、推定結果の分布とともに詳しく議論
- **Calibration データで条件づける場合:** 無限大の事例数があれば、予測対象を $1-\alpha$ で含む
  - Calibration (“Test”) データが 1000 事例程度あれば、$1-\alpha$ で”概ね含む”

2.11 練習問題

- “任意の方法で”推定したモデルについて、予測区間が計算できる
  - 「“川田がダーツを投げる”と 2 が出たので、子供の数は 2 と予測し続けるモデル」についても、$1-\alpha$で予測対象を含む区間を計算できる
  - “子供の数 $=$ 100”でも計算できる
- なぜ?

2.12 Reference