記述モデル

経済学のための機械学習入門

川田恵介

keisukekawata@iss.u-tokyo.ac.jp

2026-10-28

1 社会の把握: Get started

1.1 モデル

- 社会における平均価格はどの程度上昇したのか?
- 以下のモデルを推定する

$$\text{取引価格} \simeq \beta_0 + \beta_1 \times year$$

- `year`: 2025 年の取引であれば 1, 2024 であれば 0

1.2 モデルの予測

- 2024 年の平均取引価格 $\simeq \beta_0 + \underbrace{\beta_1 \times 0}_{=0}$
- 2025 年の平均取引価格 $\simeq \beta_0 + \underbrace{\beta_1 \times 1}_{=\beta_1}$
- $\beta_1 =$ 2025 年と 2024 年の平均取引価格の差

1.3 コード

```
library(tidyverse)

df <- read_csv("example.csv")

estimatr::lm_robust(price ~ year,df)
```

```
             Estimate Std. Error   t value     Pr(>|t|)  CI Lower CI Upper
(Intercept) 69.802270  0.7915731 88.181705 0.000000e+00 68.250642 71.35390
year         8.143436  1.2163824  6.694799 2.266572e-11  5.759104 10.52777
               DF
```

```
(Intercept) 10826
year        10826
```

- 「信頼区間」は、576 万円 ~ 1053 万円程度の平均価格の上昇を示唆する

2 モデルの多様な役割

2.1 モデルの活用目的

- 一見同じモデルでも、活用目的によって、要求が異なる
- ポイント: **意思決定者**が、モデルをどのように活用するのか?

2.2 意思決定問題の例

- 以下の社内会議において、“欲しい情報”は？
  - 「ある物件をいくらで下取るべきか?」
    - 個別の事例を予想
  - 「どのような中期経営計画を立てるべきか?」
    - 事業/市場/社会全体の状況把握

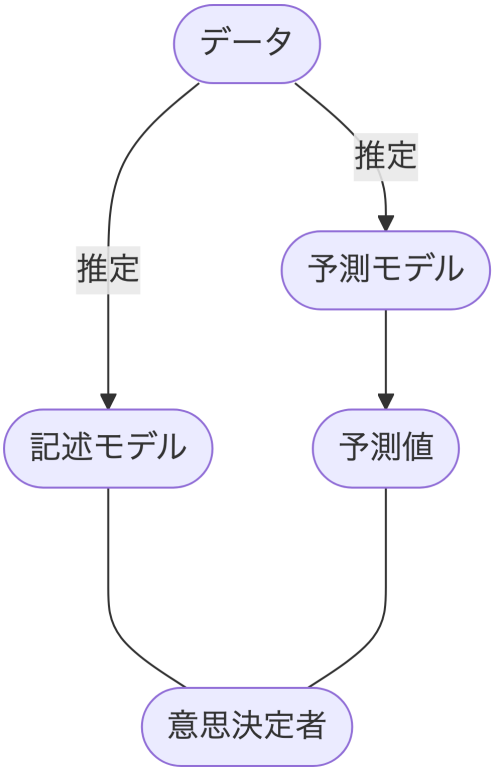
2.3 把握のためのモデル

- **経済学の伝統的用法:**「有効な action 案を提案し、その有効性を**評価**する」ための、基礎情報の提供
- **モデルの役割:** 人間の認知能力に比べて、社会は複雑すぎるので
  - その要約であるモデルの特徴を、意思決定者が把握する
  - 人間が認識できる社会の模型 = 記述モデル

2.4 予測のためのモデル

- **前回までの内容:** 個別予測やその性能指標の提供
- **モデルの役割:** 予測値の計算ツール
  - 意思決定者は、予測結果やその精度が把握できれば十分であり、モデルの詳細な特徴を”人間が”把握する必要はない
  - 予測のための”裏方”

2.5 意思決定者の目線



2.6 補論: 混乱の要因

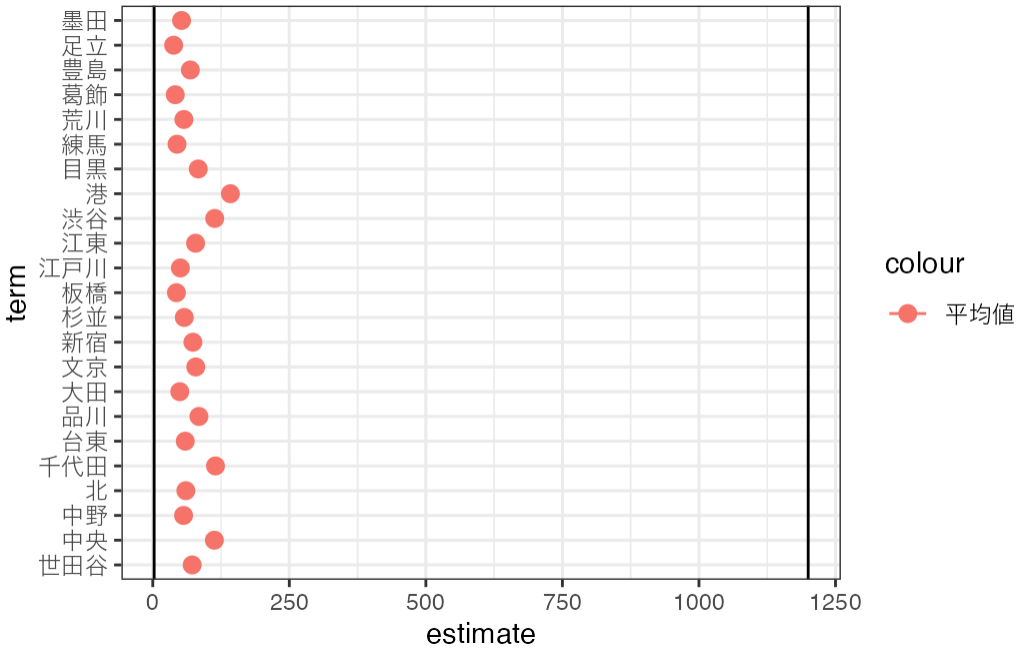
- かつては、同じ(単純な)モデルを記述と予測に用いてきた
- 正当化としては、
  - データが少なく、計算能力も限られているので、単純なモデルしか推定できない
  - “真実”は意外に単純
- 現代経済学では、どちらも”説得的”ではない

3 信頼区間

3.1 例

- 最高取引価格は港区の 1200, 最低取引価格は足立区の 2.5
- 各地域の平均取引価格を捉えているのか?

3.2 例



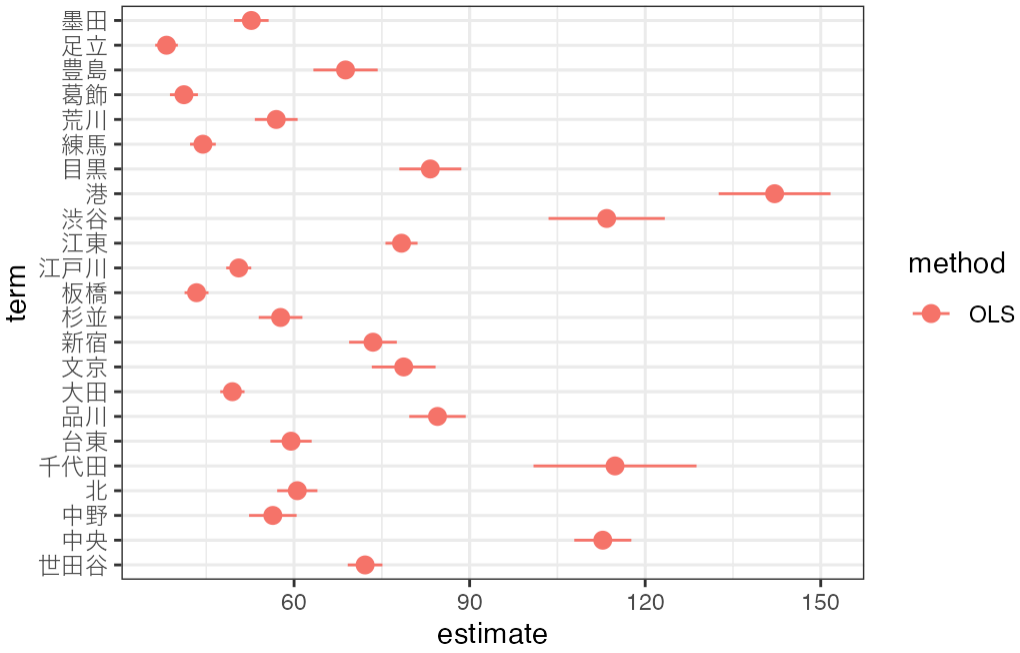
3.3 課題

- 母集団上とデータ上での平均値は、乖離する
- 「データ上での平均取引価格は 5 千万円なので、母集団での平均価格も 5 千万円」という主張は必ず「嘘」になる

3.4 信頼区間の定義

- 信頼区間 = 母集団における平均値を概ね含む区間
- 正確には事前に定めた方法で、データから算出される区間
  - 95% 信頼区間であれば「95% の確率で推定目標を含む区間」をデータから計算する方法

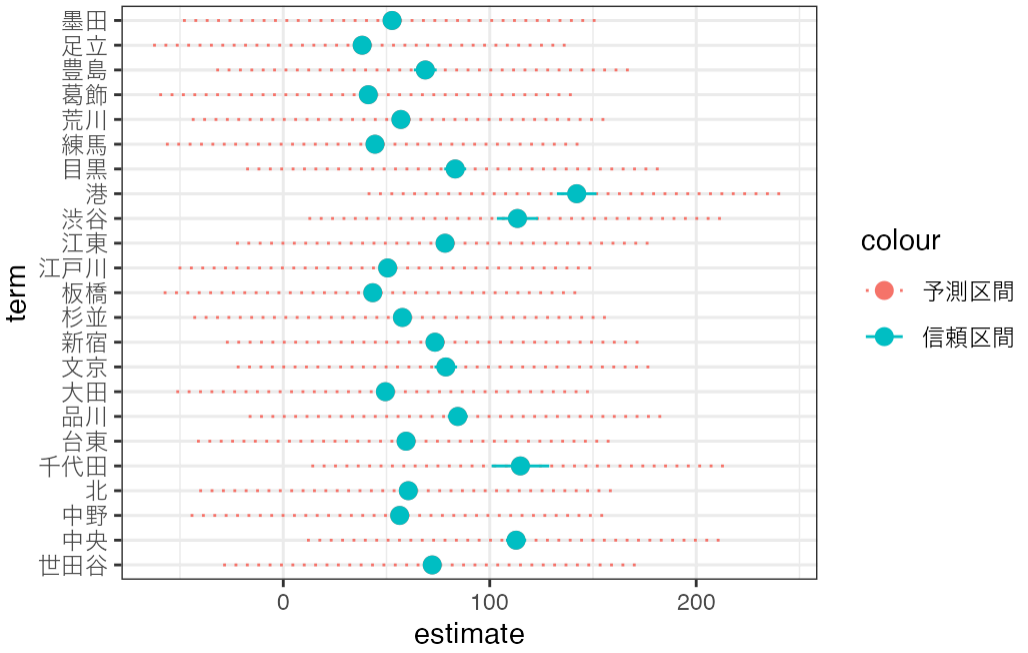
3.5 例. 各区の平均価格



3.6 予測区間

- 予測区間 = 予測対象を一定確率で含む区間
  - 母平均などを一定確率で含む区間である信頼区間とは異なる
- 一般に予測区間は、信頼区間よりも広くなる
  - 個人差(平均からの乖離)も区間に反映する必要があるため
  - 母集団のシンプルな特徴を捉えたいのであれば、“too much”

3.7 例. 各区の平均価格



3.8 例

- 典型的な錯覚: 「計算した 95% 信頼区間 (130 ~ 151) は、推定目標を 95% の確率で含む」は誤り
  - なぜ?

3.9 事前と事後

- ある**確率的事象** が、実現する前が**事前**/後が**事後**
- 例: コイントスの結果について、「表が出ると**事前に主張**」:
  - 事前確率:「50 % 正しい」かつ「50 % 間違い」
  - 事後確率: 「100 % 正しい」または「100 % 間違い」
    - 表が出たのであれば、100% 正しい (確率の”消失”)

3.10 信頼区間

- 信頼区間における確率的事象は、「データの抽出」
- 理想的な 95% 信頼区間:「(データから計算した)区間が推定目標を含む」と**主張**すると:
  - 事前確率:「95 % 正しい」/「5 % 間違い」
  - 事後確率: 「100 % 正しい」/「100 % 間違い」
- 仮定に基づき、間違いを犯す事前的確率をコントロールした主張を行う”ルール”

3.11 落とし穴

- コイントス: 事後(コイントス後)において、宣言の当否は確認できる
  - 「裏が出た」のであれば、「表が出る」という宣言は 100% (事後確率) 誤り

3.12 落とし穴

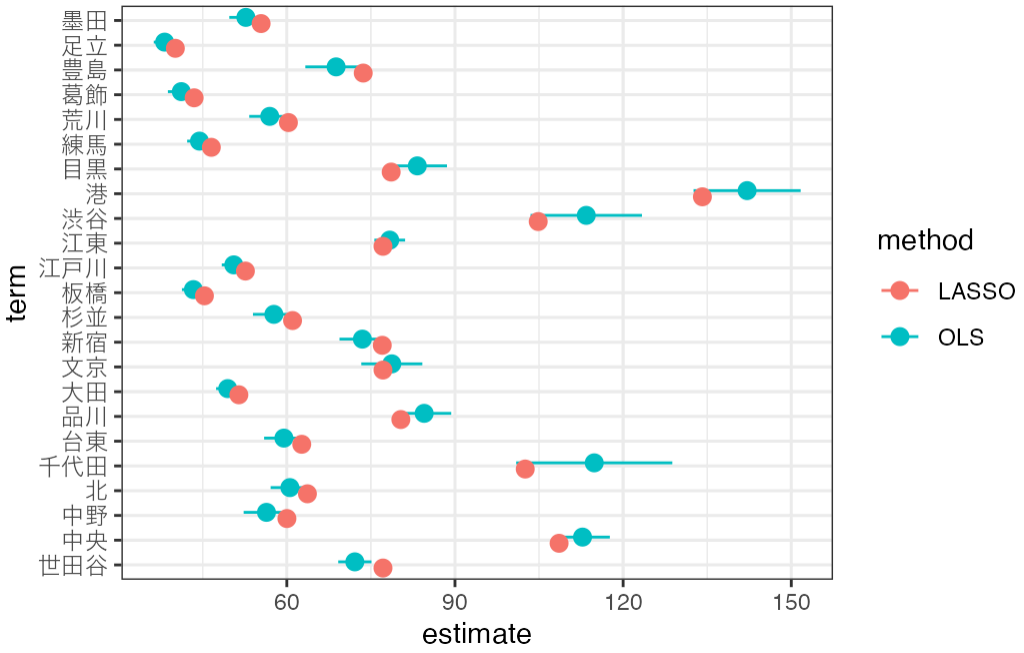
- 信頼区間: 推定目標は、データに依存せずに決まる 「不明だが確定した」値
  - 事後 (抽出したデータから計算した後)においても、宣言の当否が確認できず、事後確率も定義できない
    - 「事後確率 = 事前的確率」という**錯覚**を生み出す一因
    - 事後確率を定義したい場合、ベイズ法などを検討

4 LASSO?

4.1 論点

- 「単純な線形モデルを LASSO で推定すると、さらに単純なモデルが推定される」
  - 優れた記述モデル?
- 記述モデルの推定方法としては、問題点がある
  - 統計的推論の代表的なツールである、信頼区間の算出が難しい
    - 推定結果が扱いづらい統計的性質を持つ

4.2 例. 各区の平均価格

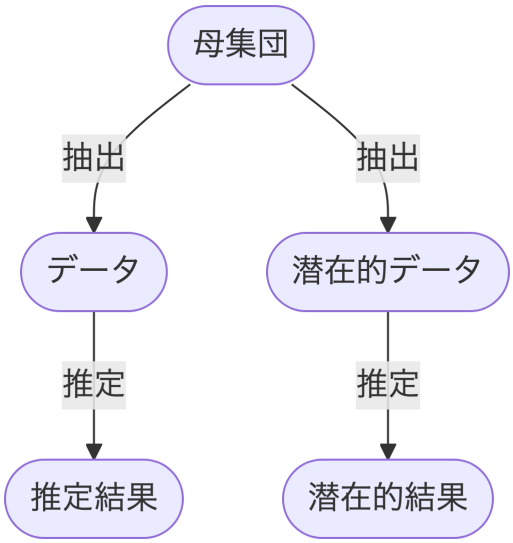


5 点推定値の分布

5.1 “統計的性質”の対象

- 信頼区間の具体的な算出方法は、推定結果の統計的性質に基づく
- 代表的な統計的性質 (一致性、漸近正規性、効率性 など) や本講義の対象は?
  - 母集団やパソコンに表示される推定値では**ない**
  - 推定結果を**計算する前**の「潜在的な無数の結果」についての性質

5.2 対象



5.3 OLS の事前的性質

- 推定目標 = 「母集団上での OLS から計算されるβ」
- 「データ $\neq$ 母集団」なので, 「母集団上での OLS $\neq$ データ上の OLS」

5.4 数値例

- 「1000 事例のデータ」を 50 個 (データ ID1,データ ID2, ...)発生させる

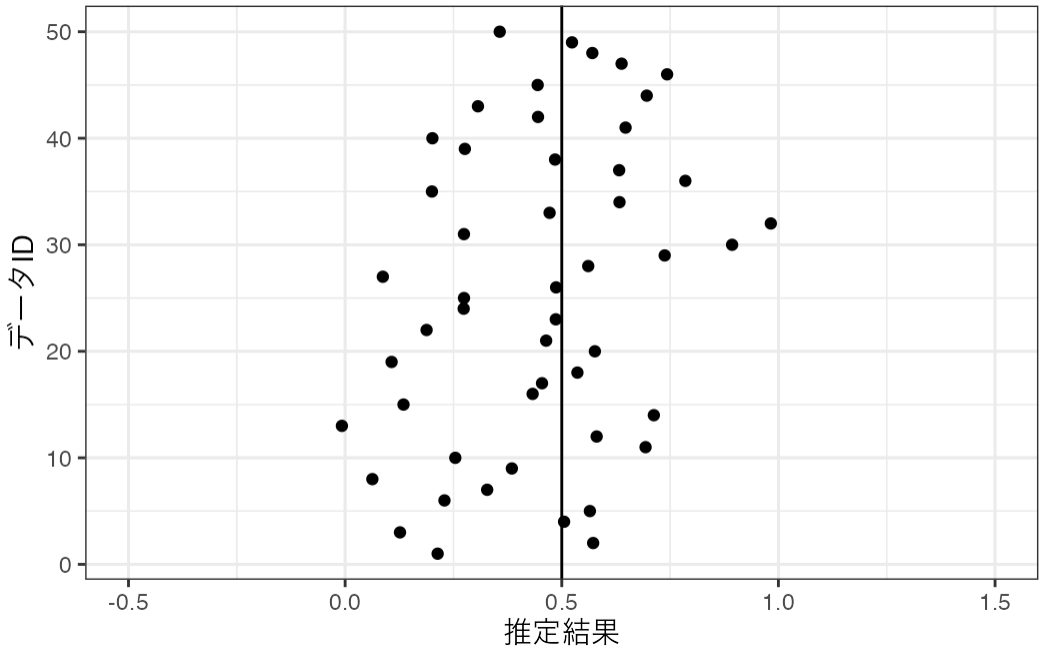
```
# A tibble: 5 × 2
  データID 推定結果
     <int>    <dbl>
1        1    0.214
2        2    0.572
3        3    0.127
4        4    0.505
5        5    0.565
```

5.5 OLS の事前的性質

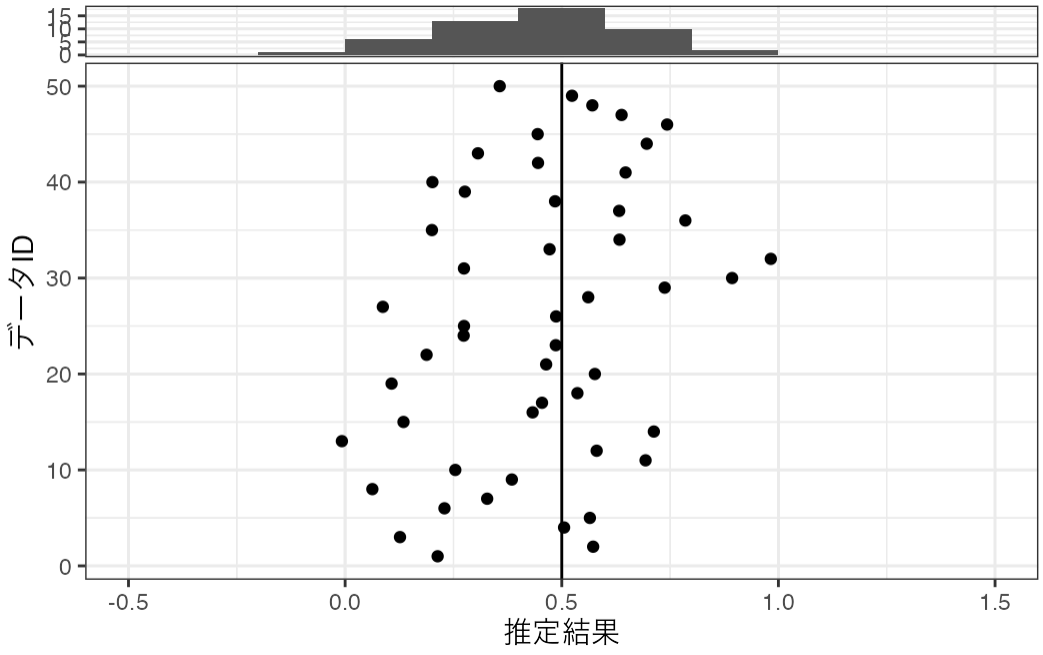
- 「データがランダム抽出 + 技術的な仮定[1]」のもとで
  - 十分な事例数があれば、平均値 = 推定目標の正規分布で近似できる[2]
  - 平均値を頂点とする富士山型の分布

[1]完全な多重共線性ではないなど
[2]漸近正規性; Asymptotic normality

5.6 数値例: 点推定値の”ダンス”



5.7 数値例: 点推定値の”ダンス”



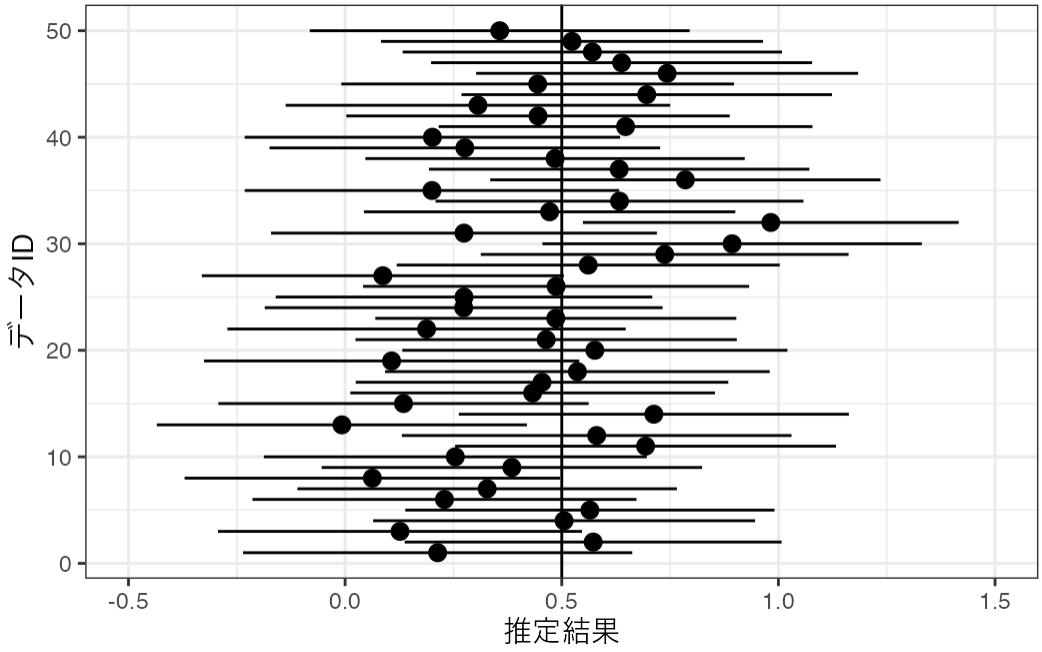
5.8 β_A についての信頼区間

・ 信頼区間の計算方法: データ上での OLS の結果 $\hat{\beta}_A$ に対して、

$$\left[\hat{\beta}_A - Q, \hat{\beta}_A + Q\right]$$

- $Q =$ データから計算する”幅”
- 幅計算の根拠は、データ上での OLS が持つ、事前的な分布の性質

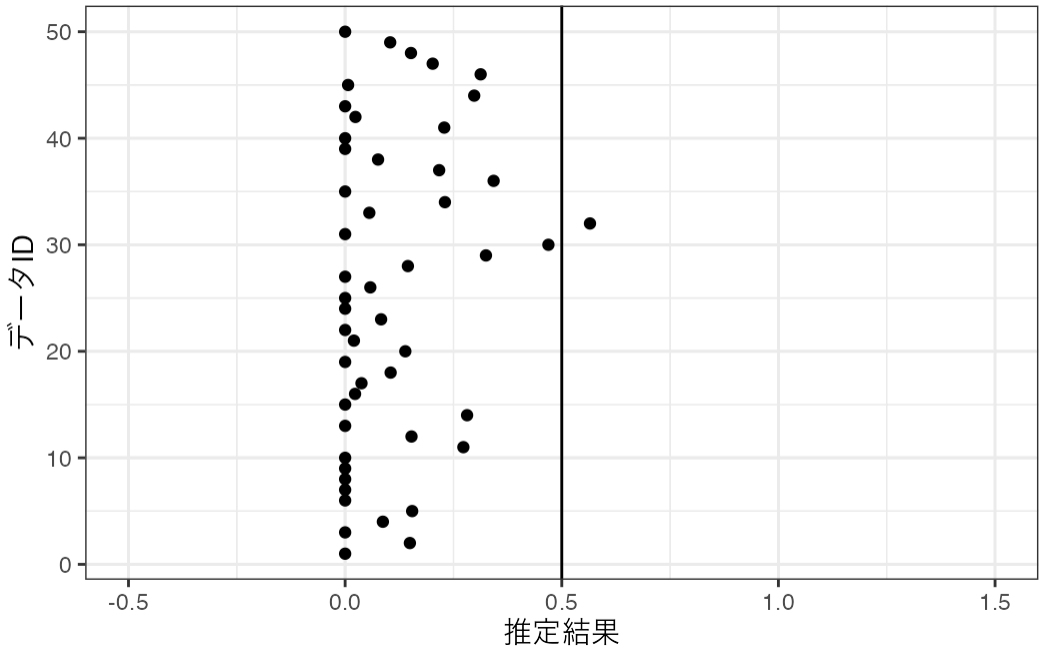
5.9 数値例: 信頼区間の”ダンス”



5.10 LASSO の問題点

- β の点推定値の事前分布が、
  - バイアスを持つ
  - 正規分布で近似できない

5.11 数値例: LASSO の”ダンス”



5.12 錯覚を避けるコツ

- 少なくとも本講義の範囲内では、確率は実在する存在ではなく、有益な分析概念 (フィクション) と見做す
  - 「いろんな可能性があるもの」の一**部について**、仮定に基づき付与できる値
    - 付与できないものもある
    - 本講義で登場する確率は、データを確認する前には定義されるが、R で計算した時点で消える

5.13 信頼区間の解釈

- さまざまな解釈ができる
- 個人的おすすめ: 仮定が正しいことを前提に
  - ある研究者が、「さまざまな母集団、推定目標、データに対して 95% 信頼区間を報告し続ける」
    - 人生の内で、誤った宣言をしてしまう割合は、概ね 5% に抑えられる
    - 研究成果の”品質管理”

5.14 Reference