比較分析

経済学のための機械学習入門

川田恵介

keisukekawata@iss.u-tokyo.ac.jp

2026-11-03

1 調整後の比較: Get started

1.1 単純比較

- 2025 年と 2024 年を比較すると, 平均価格は 576 ～ 1053 万円程度上昇

```
library(tidyverse)

df <- read_csv("example.csv")

estimatr::lm_robust(
  price ~ year,
  df
)
```

```
             Estimate Std. Error   t value     Pr(>|t|)  CI Lower CI Upper
(Intercept) 69.802270  0.7915731 88.181705 0.000000e+00 68.250642 71.35390
year         8.143436  1.2163824  6.694799 2.266572e-11  5.759104 10.52777
               DF
(Intercept) 10826
year        10826
```

1.2 調整後の比較

- 同じような広さの物件を比較した場合、 2025 年と 2024 を比較すると, 平均価格は 581 ～ 971 万円程度上昇

```
estimatr::lm_robust(
  price ~ year + (size + tenure)^2 + I(size^2) + I(tenure^2),
  df
)
```

```
               Estimate  Std. Error    t value     Pr(>|t|)    CI Lower
(Intercept) 24.23797588 4.951880613   4.894701 9.987624e-07 14.53138251
year         9.58398310 0.851884818  11.250327 3.350599e-29  7.91413276
size         0.44684826 0.201230012   2.220585 2.639974e-02  0.05240056
tenure      -0.96441186 0.137240221  -7.027181 2.234274e-12 -1.23342784
I(size^2)    0.01841211 0.002135118   8.623460 7.402221e-18  0.01422689
I(tenure^2)  0.03200557 0.002072387  15.443823 3.065435e-53  0.02794332
size:tenure -0.03956410 0.002659627 -14.875806 1.459534e-49 -0.04477745
               CI Upper    DF
(Intercept) 33.94456925 10821
year        11.25383344 10821
size         0.84129596 10821
tenure      -0.69539588 10821
I(size^2)    0.02259733 10821
I(tenure^2)  0.03606783 10821
size:tenure -0.03435074 10821
```

2 調整後の比較

2.1 記号

- 以下、見やすくするために以下の記号を用いる
  - $Y = \text{price}$, $D = \text{year}$, $X = [\text{size}, \text{tenure}]$
- X, D の値が全く同じ集団内で、Y の平均値を $E[Y \mid D, X]$
  - 例: $E[price \mid year = 1, size = 50, tenure = 10]$

2.2 推定目標

- X の値が全く同じ集団内で、D 間での Y の平均差

$$E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$$

2.3 サブグループ分析

- もし十分な事例数があれば、「X が同じグループ」に絞ってモデルを推定すれば良い

```
estimatr::lm_robust(
  price ~ year,
  df,
  subset = size == 50)
```

```
             Estimate Std. Error   t value      Pr(>|t|)   CI Lower CI Upper
(Intercept) 49.849442   1.722104 28.946819 2.772136e-112 46.4666676 53.23222
year         5.732932   2.529500  2.266428  2.381634e-02  0.7641676 10.70170
             DF
```

```
(Intercept) 545
year        545
```

2.4 問題点

- X の含める変数の数が増えると「X が同じグループ」の事例数が急速に減少する
- 例えば size=50,tenure=10, distance=5 の物件数は 1

3 重回帰

3.1 記述モデルの推定

- 事例数の問題に対応するために, 記述モデルを推定する

$$E[price \mid year, size] \simeq \beta_0 + \beta_D \times year + \beta_1 \times size$$

3.2 推定目標

- $\beta_D \simeq E[price \mid year = 1, size] - E[price \mid year = 0, size]$

3.3 例

```
estimatr::lm_robust(
  price ~ year + size,
  df
)
```

```
             Estimate Std. Error    t value     Pr(>|t|)   CI Lower   CI
Upper
(Intercept) -31.948270 2.27912057 -14.017806 2.954147e-44 -36.415764
-27.480776
year          7.762526 0.99375386   7.811316 6.182757e-15   5.814586
9.710465
size          1.734987 0.04237185  40.946703 0.000000e+00   1.651931
1.818044
               DF
(Intercept) 10825
year        10825
size        10825
```

3.4 大量のX

- 複数のXを導入することも可能

$$E[price \mid year, size] \simeq \beta_0 + \beta_D \times year + \underbrace{\beta_1 \times size + \beta_2 \times tenure}_{X=[size,tenure]}$$

3.5 モデルの複雑化

- X について複雑な定式化を行うことで, より近似の精度を高めることができる
  - $E[Y \mid D, X] =$ モデル となるので, $\beta_D = E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$

3.6 モデルの複雑化の例

- 例えば

$$E[price \mid year, size] \simeq \beta_0 + \beta_D \times year$$
$$+\beta_1 \times size + \beta_2 \times tenure$$
$$+\beta_3 \times size^2 + \beta_4 \times tenure^2 + \beta_5 \times size \times tenure$$

3.7 例

```
model <- estimatr::lm_robust(
  price ~ year +
    size*tenure*distance +
    I(size^2) + I(tenure^2) + I(distance^2),
  df
)

coef(model)[2] # yearの結果だけ抜き出す
```

```
    year
9.821886
```

```
confint(model)[2,] # yearの結果だけ抜き出す
```

```
    2.5 %    97.5 %
 8.251832 11.391941
```

3.8 X の分離

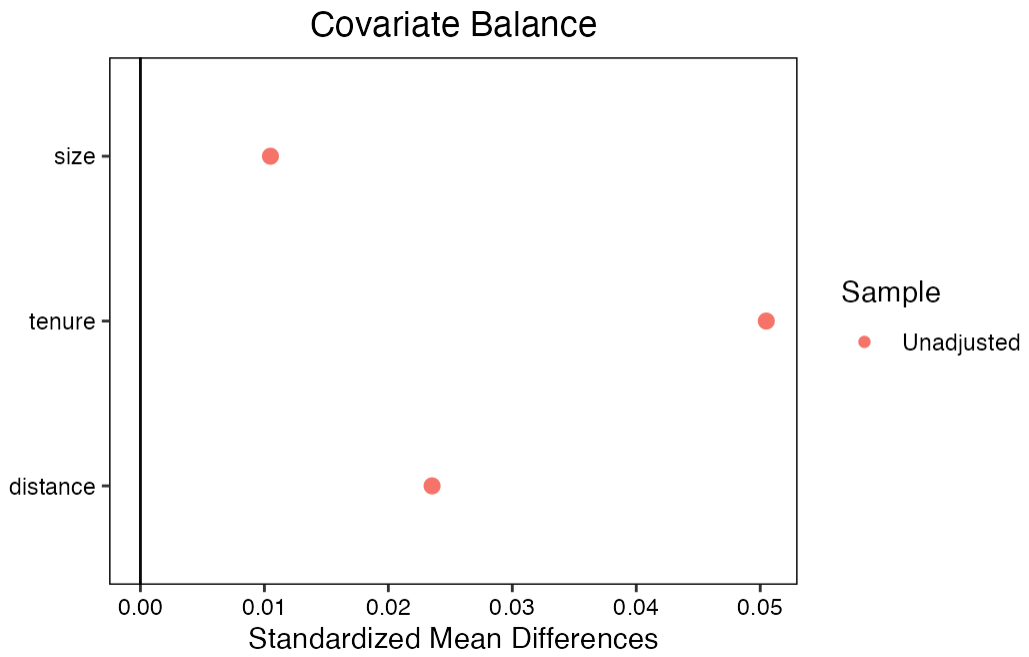
- なぜ調整後の比較で結果が変わるのか?
  - X の乖離 ($E[X \mid D = 1] - E[X \mid D = 0]$ など)を確認することが有効

3.9 例

```
Balance Measures
            Type Diff.Un
size     Contin.  0.0105
tenure   Contin.  0.0505
distance Contin.  0.0235
```

```
Sample sizes
    Control Treated
All    5507    5321
```

3.10 例



3.11 例

- 2025 年の物件の方が、
  - 広い (価格が高いことが予想される)
  - 古い (価格が安いことが予想される)
  - 遠い (価格が安いことが予想される)

3.12 モデル複雑化: 人間による把握

- 一般に難しいモデルは、人間が理解するのが難しくなる
  - 記述モデルにおいては一般に問題
- 「特定の変数D について比較する」ために記述モデルを用いるのであれば、Y と D の関係性を要約する β_D の値さえ人間が認識できれば良い

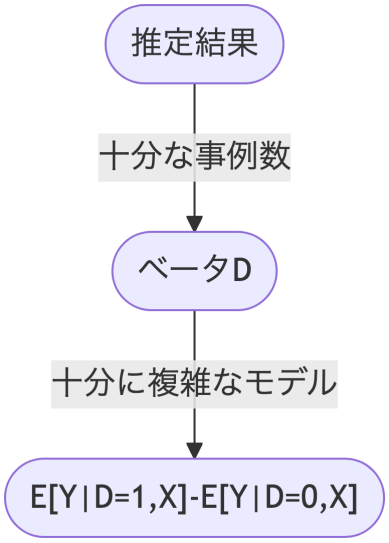
3.13 モデル複雑化: 推定精度

- モデルに含まれる β の数が事例数に近づくと、信頼区間が広がる (推定精度が悪化する)あるいは信頼区間そのもの信頼性が低下する、という弊害が生じる

- 特に X の数が多い場合、現実的な問題となる

- 解決するためには, 機械学習の活用が有効

3.14 まとめ



- X の数が多い場合, 「十分な事例数」と「十分に複雑なモデル」は深刻に対立する
  - 解決策: 機械学習の「慎重な」応用