調整後の比較: OLS と 2 重選択

経済学のための機械学習入門

川田恵介

keisukekawata@iss.u-tokyo.ac.jp

2026-11-10

1 復習: OLS による比較

1.1 アプローチ

- X が同じ事例内での, Y と D の関係性を捉えるために, 以下のモデルを推定する

$$E[Y \mid D, X] \simeq \underbrace{\beta_D \times D}_{\text{関心}} + \underbrace{\beta_0 + \beta_1 X_1 + ...}_{\text{関心の対象外}}$$

- 近似の精度を上げるために, X に関する部分を極力複雑に定式化する必要がある

1.2 問題点

- X の数が多い場合, 複雑な定式化を行うと, β_D の推定精度が極端に低下する
- モデルを単純化する必要がある
  - 伝統的方法: 研究者が経験とかんに基づいて行う
  - 本講義: データ主導の方法を紹介
    - LASSO を活用した 2 重選択法

2 2 重選択法

2.1 定義

- アイディア: 機械学習(LASSO)による「下準備を行い」、OLS や平均値などで推定目標を推定する
  - X の中から「重要ではない変数」を除外する
- 単純に LASSO で推定すると信頼区間が計算できない, という問題に対処する

2.2 選択法

- LASSO による変数選択のみを活用する

1. LASSO によって、X の中から”重要な変数” のみを選ぶ
2. 重要な変数のみモデルに導入して、OLS で推定する
3. 信頼区間を計算する

2.3 非推奨: 単一選択法

1.「X から Y を予測するモデルを推定した際に除外された変数」を除外する

- Y の予測において、特に重要そうな X が選択される
  - 問題点: 信頼区間が計算できない

2.4 例

- $Y =$ price, $D =$ year, $X =$ [size, tenure,distance, district]
- 以下のモデルを LASSO で推定し, 変数選択を行う

$$price \simeq \beta_D \times year + \beta_0 + \beta_1 \times size + ...$$

2.5 例

- 以下の TRUE の変数のみモデルに導入する

```
hdm::rlasso(
  price ~ year + poly(size,2) + poly(tenure,2) + poly(distance,2) + district,
  df
)$index
```

```
             year     poly(size, 2)1     poly(size, 2)2   poly(tenure, 2)1
             TRUE               TRUE               TRUE               TRUE
 poly(tenure, 2)2 poly(distance, 2)1 poly(distance, 2)2     district中央区
             TRUE               TRUE              FALSE               TRUE
   district中野区       district北区   district千代田区     district台東区
             TRUE               TRUE               TRUE               TRUE
   district品川区     district大田区     district文京区     district新宿区
             TRUE               TRUE               TRUE               TRUE
   district杉並区     district板橋区   district江戸川区     district江東区
             TRUE               TRUE               TRUE               TRUE
   district渋谷区       district港区     district目黒区     district練馬区
             TRUE               TRUE               TRUE               TRUE
   district荒川区     district葛飾区     district豊島区     district足立区
             TRUE               TRUE              FALSE               TRUE
   district墨田区
             TRUE
```

2.6 問題点

- データによる変数選択は、一定の間違いを犯す
  - そこそこ重要な変数を間違って除外してしまう

2.7 推奨: 2 重選択

1.「X から Y **または** D を予測するモデルを推定し、どちらからも除外された変数」 を除外する

- D と X の相関構造の情報を明示的に活用
- 「重要な変数は X の一部であり、事例数に比べて十分少ない」という仮定のもとで
  - 通常の OLS と同様の手順で信頼区間を計算できる

2.8 実例

```
hdm::rlasso(
  year ~ poly(size,2) + poly(tenure,2) + poly(distance,2) + district,
  df
)$index
```

```
 [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
[13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
[25] FALSE FALSE FALSE FALSE
```

2.9 実例

```
Y <- df$price
D <- df$year
X <- model.matrix(
  ~ 0 + poly(size,2) + poly(distance,2) + poly(tenure) + district,
  df)

model <- hdm::rlassoEffect(
  x = X,
  y = Y,
  d = D
)
```

2.10 実例

```
confint(model)
```

```
      2.5 %   97.5 %
d1 8.494038 11.24328
```

2.11 実例

- TRUE が選択された変数

```
model$selection.index
```

```
    poly(size, 2)1     poly(size, 2)2 poly(distance, 2)1 poly(distance, 2)2
              TRUE               TRUE               TRUE              FALSE
      poly(tenure)   district世田谷区     district中央区     district中野区
              TRUE               TRUE               TRUE               TRUE
     district北区   district千代田区     district台東区     district品川区
              TRUE               TRUE               TRUE               TRUE
    district大田区     district文京区     district新宿区     district杉並区
              TRUE              FALSE              FALSE               TRUE
    district板橋区   district江戸川区     district江東区     district渋谷区
              TRUE               TRUE               TRUE               TRUE
      district港区     district目黒区     district練馬区     district荒川区
              TRUE               TRUE               TRUE               TRUE
    district葛飾区     district豊島区     district足立区     district墨田区
              TRUE              FALSE               TRUE               TRUE
```

2.12 ２重選択の性質

- 除外される変数は、Y とも D とも関連性が薄い変数のみ
  - 推定結果に大きな影響を与える変数は除外されにくい
- 十分な事例数があれば信頼区間を計算できる

2.13 Reference